https://hjfy.top/arxiv/2609.38905

EmbodiRSI：递归自我改进用于数据高效型机器人适应

Haoran Lang[1,2,*] **Haotao Lu**[1,2,*] **Shiyu Sang**[1,2,*] **Haoyang Luo**[1]

Guo Chen[1] **Qun Li**[1] **Jingyi Yu**[1] **Ye Shi**[1,2,†] **Jingya Wang**[1,2,†]

[1]InstAdapt [2]ShanghaiTech University

EmbodiRSI Project Page

{langhr2025,luht2025,sangshy2025,luohy12024,chenguo2024,
liqun2024,yujingyi,shiye,wangjingya}@shanghaitech.edu.cn

*这些作者对这项工作贡献相同。

†通讯作者：王静雅 (wangjingya@shanghaitech.edu.cn)，施烨 (shiye@shanghaitech.edu.cn)。

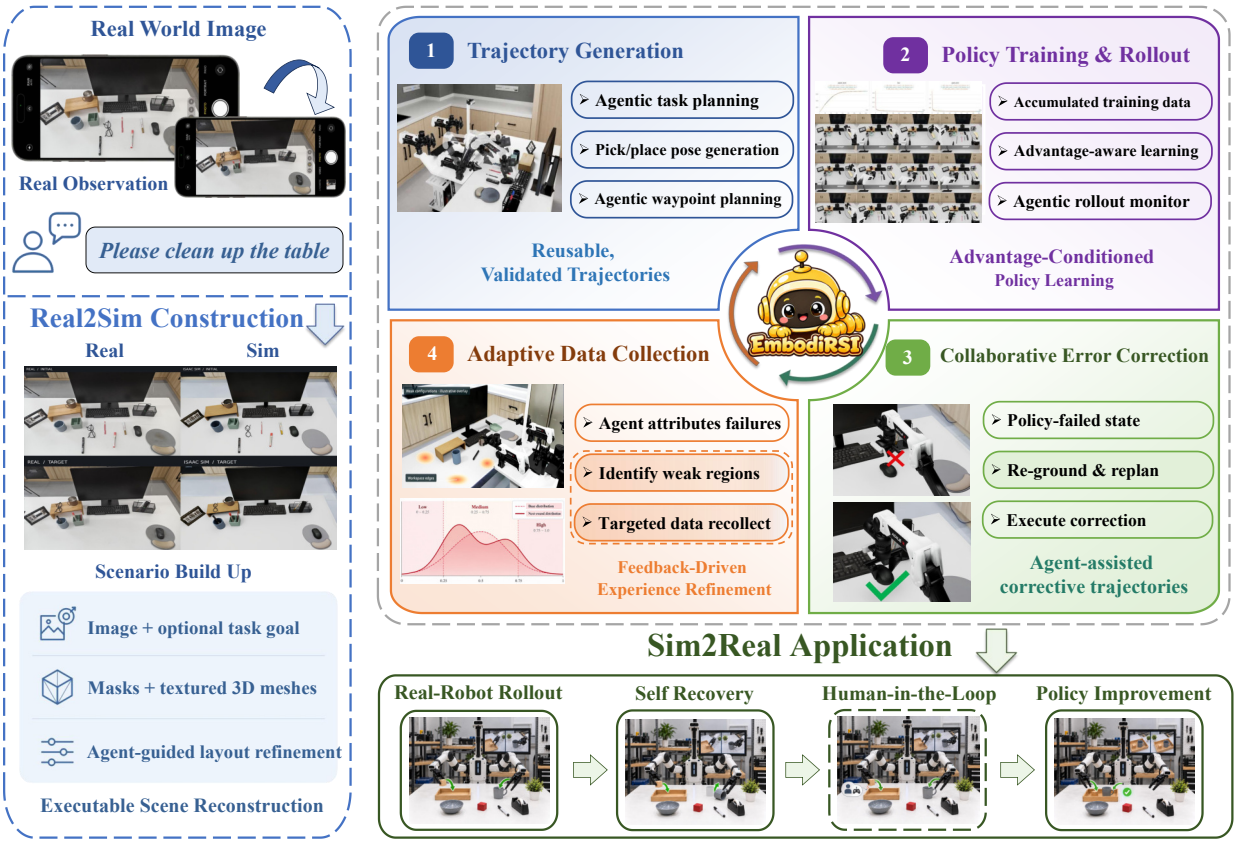


图 1: EmbodiRSI 概述。真实世界观测和任务目标指导可执行仿真环境的构建以及有效示范的生成。在此环境中，策略回放反馈引导协作式错误修正与自适应数据采集。由此产生的经验用于更新下一回合的策略，形成递归的自我改进环。随后，一个小型真实世界人机协同（HIL）数据集对策略进行微调，以实现自主部署。

Abstract

将机器人操作策略适应到新任务和环境仍然高度依赖数据，而进一步改进所需的数据又取决于当前策略的能力和失败模式。我们提出了 EmbodiRSI，一种在真实-仿真-真实（real-to-sim-to-real）情景下实现递归自提升（RSI）的 Agentic 系统。该系统从目标部署情景构建特定任务的仿真环境，并将其作为低成本环境，在转移回物理世界之前用于迭代式策略改进。EmbodiRSI 利用策略执行反馈来指导后续的经验采集和策略更新。两种互补机制闭合了这一环：*协作式错误纠正*从策略达到的状态生成由智能体辅助的修正轨迹，而 *自适应数据采集*则将专家示范生成引导至当前策略的薄弱环节。特定任务的仿真环境作为可重复使用的工件空间，支持策略预热、可重复评估、故障诊断以及在连续的 RSI 轮次中进行针对性的数据生成。在三个桌面环境和 14 个子任务上，经过两轮 RSI 更新，EmbodiRSI 将场景平衡的自主仿真成功率从 50.4% 提升至 83.5%。仅使用每子任务 400 条自适应仿真轨迹和十条真实世界微调轨迹，EmbodiRSI 实现了 83.1% 的场景平衡自主真实世界成功率，而采用每子任务 200 条真实世界示范进行适应的对比方法仅达到 75.0%。这些结果表明，基于反馈驱动的部署特定仿真中的递归改进，能够实现对具身策略在物理环境中的高效数据适应。

1 引言

近年来，通用机器人操作策略的进展显著扩展了单个机器人能够执行的任务范围 (Kim et al., 2024; Black et al., 2024; Intelligence et al., 2025b)，然而在新环境中的可靠部署仍然具有挑战性。部署过程中常常暴露出原始训练分布未能充分覆盖的系统性失败模式。重要的是，随着策略的改进，这些失败模式也会发生变化：一些弱点被解决，而剩余的错误则集中在不同的状态或配置上。因此，有效的适应不仅需要固定的训练集，更需要一种学习系统，该系统能反复评估当前策略，识别其剩余的薄弱环节，并获取有针对性的经验以实现后续改进，且无需依赖昂贵的物理数据采集和每次迭代中的人工干预。

缺失的环节在于 *观察到失败*与 *获得对后续改进有用的经验*之间。在一个回合中，一次失误的抓取或移动的物体可能会使机器人处于常规示范中不存在的状态。在多个回合之间，重复出现的失败揭示了任务分布中最为需要额外经验的区域。数据集聚合监督学习器引起的状态 (Ross et al., 2011)；干预与恢复方法将执行错误转化为训练经验 (Hoque et al., 2024; Lin et al., 2025)；而近期的 Agentic 系统则协调收集、学习和执行过程 (Li et al., 2026)。这些方向促使我们提出一个更广泛的问题：

机器人能否利用其当前策略的反馈来同时确定如何从故障中恢复以及应获取何种经验以用于下一次策略更新？

我们引入了 **EmbodiRSI**，这是一个用于在 *真实-仿真-真实*（R2S2R）工作流中的 *递归自我改进*（RSI）的 Agentic 学习系统（图 1）。从目标物理工作空间出发，EmbodiRSI 构建一个特定任务的仿真环境，在该环境中，策略可反复进行评估与优化，随后再转移回现实世界。当前策略生成轨迹，执行结果决定应获取的下一阶段经验，而所得经验则用于更新策略。更新后的策略再次被评估，产生新的反馈以进入下一轮迭代。通过这种方式，经验分布随着策略的演进而动态变化，而非预先固定。

两个互补的机制完成了这一 RSI 环。*协作式错误纠正*在回合内运行：当策略执行失败时，智能体引导从策略实际达到的中间状态进行恢复，生成修正轨迹而不重置任务。*自适应数据采集*在回合间运行：智能体汇总回溯结果，识别反复出现的失败模式，并将后续专家示范生成重新定向至当前策略仍较薄弱的配置。这两个机制共同将执行反馈转化为后续策略更新的目标训练经验。随后，更新后的策略再次被展开，以揭示其剩余的局限性。

特定任务的仿真为这种递归优化提供了高效且可重复执行的工作空间。在获取目标部署环境的观测信息和任务规范后，EmbodiRSI 重构并组织相应的虚拟工作空间，同时轨迹智能体生成经过验证的专家示范，用于策略初始化及后续的自适应数据收集。同一环境支持可重复的评估、故障诊断、错误修正和定向数据生成。利用几何推理、碰撞检测和运动规划工具对生成的轨迹和恢复动作进行验证。经过仿真中的迭代优化后，仅需在物理工作空间中收集少量人机协同（HIL）轨迹，即可对策略进行微调，以实现自主的现实世界执行。

我们的评估遵循从任务特定仿真中的递归改进到对应物理环境部署的 R2S2R 进展。在三个桌面环境和 14 个子任务中，经过两次 RSI 更新（从 R0 到 R2），EmbodiRSI 将场景平衡的自主仿真成功率从 50.4% 提升至 83.5%。为隔离反馈驱动经验获取带来的收益，我们在两个环境中进一步对比了自适应收集与静态收集，保持保留轨迹数量一致。在每个子任务累计 400 条仿真轨迹的预算下，自适应收集相较于静态收集，使场景平衡的仿真成功率提升 20.6 个百分点，预精炼阶段的真实世界成功率提升 12.9 个百分点。在完整的三环境评估中，EmbodiRSI 使用每子任务 400 条自适应仿真轨迹和仅十条真实世界精炼轨迹，实现了 83.1% 的场景平衡自主真实世界成功率，而使用每子任务 200 条真实世界示范进行适应的方法仅达到 75.0%。

我们的主要贡献如下。

- 我们提出了 EmbodiRSI，这是一种在 R2S2R 工作流中的 Agentic 递归自我改进系统，其中策略执行反馈会迭代地引导特定任务仿真环境中的经验获取和策略更新。
- 我们开发了两种互补机制来闭合 RSI 环路：*自适应数据采集*，该机制将专家示范引导至当前策略的薄弱环节；以及 *协作式错误修正*，该机制通过智能体引导的恢复过程，从策略达到的失败状态生成纠正轨迹。
- 我们展示了在多种操作任务中逐步改进策略并实现数据高效的现实世界适应。与使用大量真实世界示范的适应方法相比，EmbodiRSI 仅需少量物理微调数据即可实现更高的现实世界成功率。

2 相关工作

基于仿真的可扩展数据生成。 RoboGen 和 GenSim 生成环境或任务 (Wang et al., 2023; 2024)；MimicGen、SkillMimicGen、DexMimicGen 和 DemoGen 扩展源示范数据 (Mandlekar et al., 2023; Garrett et al., 2024; Jiang et al., 2025b; Xue et al., 2025)。RoboTwin 使用生成式数字孪生 (Mu et al., 2025)，而 RoboTwin 2.0 通过领域随机化实现双臂数据的规模化生成 (Chen et al., 2025)。SAGE 和 V-CAGE 集成 Agentic 生成与验证 (Xia et al., 2026; Liu et al., 2026)。部署特定的 Real2Sim2Real 系统将重建的工作空间连接至策略学习与迁移 (Torne et al., 2024; Fang et al., 2025; Han et al., 2025; Dan et al., 2025; Patel et al., 2025)。EmbodiRSI 将这些能力作为基础设施，用于重复的策略优化：初始训练后工作空间仍可使用，而回放反馈会修正其中所生成的经验。

通过真实到模拟再到真实的机器人学习。 Real2Sim2Real 通过从真实观测中重建或生成仿真，学习策略或在仿真中扩展机器人经验，并将所得策略或行为转移回真实机器人，从而减少对真实世界数据的需求。代表性系统包括 RialTo (Torne et al., 2024)、RL-GSBridge (Wu et al., 2025)、RoboGSim (Li et al., 2024)、Re^3 Sim (Han et al., 2025)、RoboSimGS (Zhao et al., 2026)、ReBot (Fang et al., 2025) 以及 X-SIM (Dan et al., 2025)。与之密切相关的从实到仿及照片级真实数字孪生系统，如 IKER (Patel et al., 2025)、Scalable Real2Sim (Pfaff et al., 2025)、RoboPearls (Tao et al., 2025)、GSWorld (Jiang et al., 2025a) 以及 Real2Sim-Eval (Zhang et al., 2025)，展示了仿真作为连接真实观测与机器人执行的桥梁的价值。EmbodiRSI 进一步在

此范式基础上，引入了由智能体驱动的闭环，统一了场景构建、轨迹生成、策略训练、滚动评估、故障恢复和数据优化等环节。

机器人学习的递归自我改进 近期关于递归机器人自我改进的研究探讨了如何利用自身不断演化的行为所产生的经验，迭代地优化策略。SOAR (Zhou et al., 2024) 使用基础模型来指导自主数据采集和从未标记经验中学习，而 RECAP (Intelligence et al., 2025a) 通过优势调节结合示范、自主经验与纠正反馈。VERITAS (Zhang and Shah, 2026) 利用视觉验证对自主滚动展开进行筛选，以促进后续的策略改进，RoboClaw (Li et al., 2026) 将自主数据采集、学习与执行整合进一个统一的迭代环中。RISE (Yang et al., 2026) 进一步通过在学成的世界模型中进行想象式滚动和优势估计来提升策略。EmbodiRSI 沿着这一方向，将回合内恢复与回合间回忆相结合，使得每次策略迭代产生的经验都能为后续更新提供信息。附录 F 提供了更多背景信息。

3 方法：一种用于递归策略自我改进的系统

EmbodiRSI 将策略最优化与获取下一个训练经验相结合。在第 k 轮，设 π_k 为当前场景特定的策略，$\mathcal{D}_k$ 为累积的仿真数据集，$p_k(c)$ 为示范收集配置的分布。一个配置 c specifies 一个源物体、目标锚点、指令、抓取和航路点程序，以及允许的重置值域。一个策略覆盖场景中的所有子任务。第 3.1 节和 3.2 节描述了支持基础设施；第 3.3 节提出了 RSI 环。

3.1 RSI 的可执行环境

给定一个桌面图像，以及可选的目标图像或语言目标，EmbodiRSI 通过完全自动化的、由智能体协调的流水线构建初始场景 $\mathcal{S}_0$ 和组织化的目标场景 $\mathcal{S}_{\text{org}}$。场景智能体识别物体，并调用 SAM 3 (Carion et al., 2026) 获取实例掩码，以及调用 SAM 3D (Chen et al., 2026) 重建相应的带纹理网格。随后，它应用智能体引导的自适应碰撞修正来解决相互穿透问题，同时保留支撑和包含关系。为了构建组织化的目标场景，智能体建立粗略的任务关系，并利用渲染视图和几何检查优化物体位姿。

此场景是 RSI 的 *训练环境*：它支持可重复的重置，暴露物体状态以供训练期间诊断，并允许从策略失败的状态中恢复。该环境在整个学习过程中被保留，而不仅仅用于生成初始数据集。场景构建、几何运算符和组织示例详见附录 B 和 C。

3.2 可重复使用的训练经验来源

轨迹智能体将场景对编译为可执行的任务配置和有效示范。它提出物体空间的路径，通过 GraspGen (Murali et al., 2025) 候选方案进行投影，并利用 cuRobo (Sundaralingam et al., 2026) 验证完整的机器人程序。准入需经过扫掠物体碰撞检测、多视角审查、顺序运动可行性以及执行时任务检查。不可行的候选方案将被修复并重新验证，或予以拒绝。

存储的航点遵循源或目标锚点。重置后，它们会重新基于测量到的物体位姿进行定位，并从当前机器人状态重新规划。此可复用接口将智能体决策与可执行的监督控制连接起来，用于初始采集、恢复以及目标回收。附录 B.2 详细介绍了编译和执行过程。

3.3 智能体引导的递归策略自优化

初始示范可能省略了由学习器不完善引起的状态以及训练后仍困难的配置。EmbodiRSI 在两个时间尺度上解决这些差距（图 2）：恢复机制在回合内提供纠正性监督，而回放诊断则在回合之间优化示范收集分布。累积的经验用于更新策略，从而闭合如算法 1 所总结的环路。

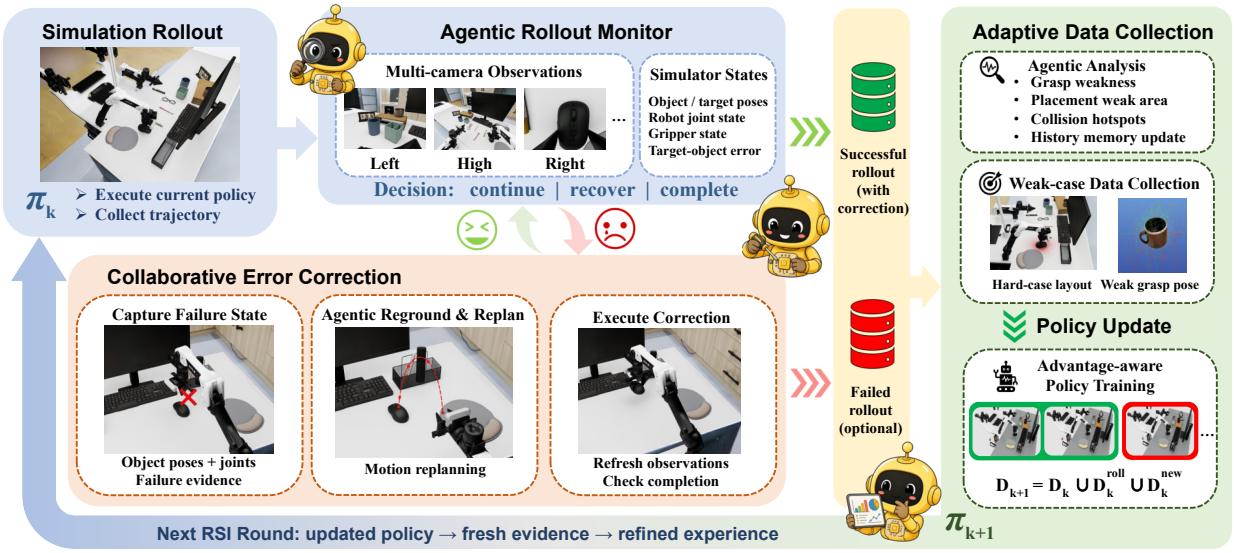


图 2: EmbodiRSI 中的递归自我改进环。轨迹监控器结合多摄像头观测和模拟器状态，以在不重置当前状态的情况下触发恢复。失败分析指导有针对性的数据采集。成功完成的轨迹（包括纠正后完成的轨迹）以及新生成的示范数据被累积，用于更新下一轮的策略。外部恢复仅在训练期间使用；评估过程完全自主。

3.3.1 Agentic Rollout 监控

在一次滚动更新 $\tau^{\pi_k} = \{(o_t, x_t, a_t)\}_{t=1}^{T}$ 期间，监控智能体将时间图像窗口、动作历史记录以及模拟器对象/机器人状态 x_t 组合在一起：

$$y_t = \mathcal{A}_{\mathrm{RSI}}(o_{t-w:t}, x_t, a_{1:t}, l), \qquad y_t \in \{\texttt{continue}, \texttt{recover}, \texttt{complete}\}. \tag{1}$$

视觉证据可识别遗漏抓取、滑移和错误放置；程序化检查测量目标-物体误差和夹持器状态。完成任务需要同时具备视觉判断和几何上的成功。恢复操作受置信度、冷却时间、尝试次数预算以及物体持握测试的限制，从而避免中断正在进行的有效运输过程。决策记录包含配置标识符、场景状态和失败证据。模拟器中的物体位姿支持这些训练工具，但并非学成策略的输入。

3.3.2 协作式错误更正

恢复必须解决策略实际达到状态下的任务，而不是从初始状态重放一次干净的示范。在恢复触发点 t_f ，将一个正常的抓取姿态传输到当前物体位姿：

$$T_g^{\mathrm{cur}} = T_o^{\mathrm{cur}} (T_o^0)^{-1} T_g^0. \tag{2}$$

此处，T_o^{cur} 和 T_o^0 分别表示物体 o 的当前状态和初始状态。候选配置以确定性顺序进行探测，且不推进模拟器。从 当前关节状态规划进入运动，并将目标重新定位到当前场景。该修正可提供从进入至抓取的运动，或继续执行剩余的操作程序。

诊断与规划暂停仿真进展。纠正后，系统刷新观测值，检查完成情况，并可能在恢复门条件下将控制权交还给策略。我们分别记录恢复请求、执行的纠正操作以及最终回合的结果。成功的延续提供了来自不完美状态的动作监督，这些状态可能被正常示范所忽略。恢复过程从策略失败的状态中提供纠正性训练经验，而性能评估则仅使用学成的策略。

3.3.3 自适应数据采集

智能体引导的数据采集根据当前策略诊断出的弱点调整采集分布。每轮采集结束后，智能体将最终失败归因于源对象重置、目标锚点重置或两者皆非；存储的归因结果可在无需额外 VLM 调用的情况下复用。对于重置主体 s ，其具有非简并的、配置特定的值域 $[\ell^s, h^s]$ ，我们将其位置归一化到公共网格，并计算归因失败率：

$$u^s(x,y) = \left(\frac{x-\ell_x^s}{h_x^s-\ell_x^s}, \frac{y-\ell_y^s}{h_y^s-\ell_y^s} \right), \qquad \widehat{r}_{k,b}^s = \frac{U_{k,b}^s}{N_{k,b}^s}. \tag{3}$$

此处，$N_{k,b}^s$ 统计在单元 b 中具有有效主体位置的已完成监控回合数，而 $U_{k,b}^s$ 仅统计可归因于 s 的最终失败次数。单元选择需要足够的观测数据和可归因的失败次数，同时失败率需超过主体级别的全局失败率。在恢复后成功的回合不计入分子；这些统计量描述的是辅助收集过程，而非无辅助测试性能。

选定的单元被映射回世界坐标，以限制相应的重置值域，包括在充分支持情况下的偏航角。后续演示生成的配置从该范围内采样。

$$p_{k+1}(c) = (1-\alpha)p_0(c) + \alpha p_{\mathrm{hard},k}(c), \qquad 0 \le \alpha \le 1. \tag{4}$$

此处，$p_{\mathrm{hard},k}$ 将采样集中在已诊断的弱配置上，而基础组件则保留对 $\alpha < 1$ 原始值域的访问。混合策略控制配置采样，但不决定保留轨迹的比例，后者还取决于基于执行结果的接受情况。此改进仅适用于训练数据收集；测试重置保持不变。故障集中提供了一种启发式方法，用于优先安排后续的数据采集（附录 A.2）。

3.3.4 策略更新与递归

令 $\mathcal{D}_k^{\mathrm{roll}}$ 包含保留的轨迹衍生回合，其中可能包含策略动作和修正动作，令 $\mathcal{D}_k^{\mathrm{new}}$ 包含在 p_{k+1} 下生成的有效示范。每个保存的回合仅计数一次。下一个数据集是

$$\mathcal{D}_{k+1} = \mathcal{D}_k \cup \mathcal{D}_k^{\mathrm{roll}} \cup \mathcal{D}_k^{\mathrm{new}}. \tag{5}$$

策略接收头部相机和手腕相机的 RGB 图像、一个 14 维的机器人状态（每只手臂包含六个关节位置和一个夹持器值）以及一条指令。遵循 RECAP (Intelligence et al., 2025a)，一个任务条件化的价值模型对累积的经验进行标注：

$$\widehat{A}_t^{(n)} = R_t^{(n)} + V_\phi(o_{t+n}, l) - V_\phi(o_t, l), \qquad z_t = \mathbb{I}[\widehat{A}_t^{(n)} > \delta]. \tag{6}$$

实现中设定 $R_t^{(n)} = 0$ ，$n = 50$ ，因此二元条件依赖于值估计的变化。令 $\widetilde{\mathcal{D}}_{k+1}$ 表示标注数据，策略更新最小化

$$\mathcal{L}_\pi(\theta) = \mathbb{E}_{(o_t,l,a_t,z_t)\sim\widetilde{\mathcal{D}}_{k+1}} \left[\ell_{\mathrm{BC}}\big(\pi_\theta(\cdot \mid o_t, l, z_t), a_t\big) \right]. \tag{7}$$

记录下的动作仍作为监督目标，而优势标签以文本形式提供，作为动作预测的条件。该公式将 RSI 生成的经验整合到策略学习中。更新后的策略 π_{k+1} 生成下一轮的滚动执行，从而指导纠正性监督和后续数据采集的优化。轮次数量和保留数据配额事先确定；反馈在该计划内引导经验获取。

协调与现实世界的适应。 在外部层级，基于 OpenClaw 的调度器通过模型上下文协议（MCP）接口协调完整的 RSI 工作流。（附录 A.3）。仿真 RSI 后，每个子任务保留的十个真实世界人机协同 (HIL) 轨迹，使用相同的学成公式对选定策略进行优化。操作员修正残余执行错误，例如不稳定的抓取和不准确的放置。最终的仿真与物理测试独立于训练数据采集，并禁用智能体接管、规划恢复和人工修正。因此，测试时的重试行为完全由策略自身所学成。

Algorithm 1 EmbodiRSI: recursive policy self-improvement

Require: Deployment observations and goals, base distribution p_0, round/data budgets

Construct the simulator; compile validated task configurations
Collect initial demonstrations $\mathcal{D}_0$ and train π_0
for each scheduled RSI round k **do**
    Roll out π_k; diagnose execution and request eligible state-conditioned recovery
    Retain rollout-derived episodes $\mathcal{D}_k^{\text{roll}}$, counting each episode once
    Attribute final failures; form p_{k+1} by Eq. (4)
    Generate and validate new demonstrations $\mathcal{D}_k^{\text{new}}$ under p_{k+1}
    Accumulate $\mathcal{D}_{k+1}$; annotate and train π_{k+1} by Eqs. (5)–(7)
end for
Refine the selected policy with a small real-world human-in-the-loop (HIL) dataset
Evaluate independently with the learned policy alone

4 实验

实验情景。 我们使用一个 14 自由度的双臂 ALOHA (Zhao et al., 2023)，配备两个腕部摄像头和一个头部摄像头，与仿真观测相匹配。配对的工作空间包括办公桌（S1，六个子任务）、厨房桌（S2，四个）以及家用桌（S3，四个）（图 3）。每个训练情景在每种场景下使用一个策略。R0 从预训练的 $\pi_{0.5}$ 检查点 (Intelligence et al., 2025b) 初始化。后续的 RSI 轮次从上一轮的策略继续训练，并使用累积的数据集。价值模型采用从同一检查点初始化的视觉-语言骨干网络，并额外添加一个价值预测头。我们的智能体系统基于 GPT-5.5 构建，并使用 Isaac Sim 作为仿真平台。子任务共享仿真/物理目标定义（表 C.1），并单独进行评估，而非作为完整的整理序列进行评估。

培训预算与评估。 R0/R1/R2 分别使用每子任务 50/200/400 累计的保留仿真训练轨迹。R0 为初始策略；R1 和 R2 采用收集-训练更新方式。+10 表示每子任务增加十条真实世界人机协同 (HIL) 优化轨迹。所有测试均为仅策略型，不依赖外部恢复机制。每任务和情景运行十次物理试验；仿真测试次数根据任务-检查点对而异。场景均衡表示对各类场景赋予相等权重。附录 D 提供了分配与统计详情。

4.1 策略在 RSI 轮次中是否得到改善？

场景均衡的自主仿真成功率从 R0 的 50.4% 提升至 R1 的 70.7% 和 R2 的 83.5%（图 4）。所有 14 个子任务均从 R0 到 R2 有所改善，尤其在最初具有挑战性的任务上提升显著。例如，S1 中的黑色笔放置任务成功率从 14.0% 提升至 76.5%，而 S2 中的胡萝卜放置任务初始表现已接近上限，提升空间有限。这些结果表明，EmbodiRSI 所评估的 RSI 轮次逐步生成更强的自主策略。

定性观察结果与 EmbodiRSI 的两条反馈路径一致。早期策略在抓取失败后仍继续执行正常的传输动作，而后期策略则更可靠地完成抓取，并有时会重新尝试先前失败的操作，部分重试最终成功完成了任务。抓取失败多发生在物体位于边缘位置时，尽管这些位置并未显示为不可达或超出训练分布范围。在成功抓取后，放置失败也时有发生，特别是在物体未能进入狭窄的目标开口时。这些执行错误与任务选择错误不同。在 50 次演示初始化阶段，策略偶尔会混淆 S1 中的红帽标记和红笔指令。然而，在更大的仿真预算下，这种混淆并非持续出现的故障模式，大多数错误都出现在执行所请求操作的过程中。更多细节见附录 E。



图 3：成对的物理实验与仿真情景。从左至右的列分别展示办公桌（S1）、厨房桌（S2）和家用桌（S3）。顶行展示物理工作空间，底行展示其对应的仿真环境。每一列均呈现现实世界与仿真中相同场景。

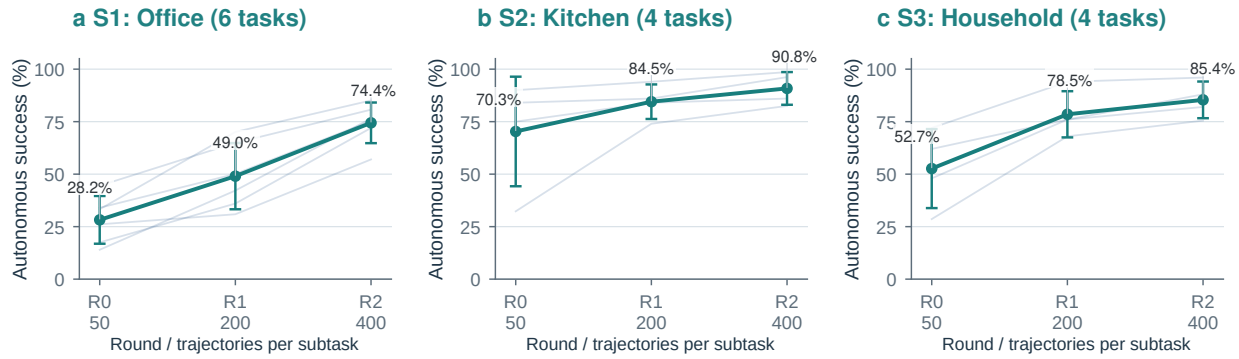


图 4：RSI 轮次中自主策略的性能。细线表示各个子任务；标记和误差条表示场景均值 ± 各子任务间的样本标准差。离散轮次 R0/R1/R2 分别保留每个子任务 50/200/400 条模拟训练轨迹。

4.2 反馈在匹配轨迹数量时有帮助吗？

我们将 EmbodiRSI 与 S1 和 S3 中的静态集合进行比较，这两个场景在初始化时更为困难。两种情景均从每个子任务 50 个演示开始，并使用相同的策略架构和训练方法。静态设置在原始配置分布下持续生成演示；而 EmbodiRSI 则引入了回放衍生的经验以及目标导向的回忆。在每个子任务 200 和 400 条轨迹处，累计保留数量保持一致。

在每子任务 400 条仿真轨迹的匹配预算下，EmbodiRSI 的自适应采集方法实现了 79.9% 的场景平衡仿真成功率，相较于 Static 的 59.3%，提升了 20.6 个百分点（表 1）。在两个评估预算下，自适应采集在两个场景中的场景级平均成功率均更高。这一优势延伸至真实世界执行，在物理优化前达到 12.9 个百分点的提升，物理优化后进一步提升至 14.2 个百分点（每个子任务使用十条人机协同 (HIL) 轨迹进行策略优化）。因此，自适应仿真采集的优势在有限的真实世界优化后依然保持。详细的任务级仿真结果见附录 E。

表 1: RSI 在相同数据预算下的效果。在每个子任务下进行 400 次模拟轨迹时，S1 和 S3 场景平衡的自主成功率（%）。完成 200/400 次比较，场景级离散性和任务级异常情况保留在附录 E中。

Method	Simulation	R2S2R	R2S2R + Human in the Loop
EmbodiRSI w/o RSI	59.3	46.3	67.9
EmbodiRSI	**79.9**	**59.2**	**82.1**
Gain (pp)	+20.6	+12.9	+14.2

表 2: 数据高效的真实世界适应。成功率（%）为各子任务的均值 ± 样本标准差；最后一列对场景进行同等权重。R1/R2 每个子任务使用 200/400 条模拟轨迹；+1 表示增加十条真实人机协同 (HIL) 轨迹。仅真实标签给出每个子任务的示范次数。每个子任务/情景有十个自主测试试验。

Training setting	S1: Office $n = 6$ tasks	S2: Kitchen $n = 4$ tasks	S3: Household $n = 4$ tasks	Scene-balanced mean
R1	43.3 ± 22.5	60.0 ± 8.2	52.5 ± 9.6	51.9
R1+10	63.3 ± 13.7	82.5 ± 5.0	75.0 ± 17.3	73.6
R2	53.3 ± 32.0	70.0 ± 14.1	65.0 ± 12.9	62.8
R2+10	$\mathbf{81.7 \pm 13.3}$	$\mathbf{85.0 \pm 12.9}$	$\mathbf{82.5 \pm 9.6}$	**83.1**
Real-only 10	13.3 ± 13.7	45.0 ± 5.8	20.0 ± 8.2	26.1
Real-only 100	56.7 ± 15.1	62.5 ± 5.0	52.5 ± 5.0	57.2
Real-only 200	70.0 ± 6.3	77.5 ± 9.6	77.5 ± 9.6	75.0

4.3 RSI 能否实现高效的数据现实世界适应？

每子任务包含 400 条模拟和 10 条真实世界微调轨迹时，EmbodiRSI 在场景平衡的自主真实世界成功率上达到 83.1%，而仅使用 200 条真实演示进行真实世界适应的方法仅为 75.0%（表 2）。在每个场景中，其观测到的平均成功率更高，且所保留的物理训练轨迹仅为原来的二十分之一。

在 zero-shot 部署中，静态策略和 RSI 策略在存在姿态变化的情况下通常都能接近目标物体。狭窄的放置区域使接近接触错误变得明显，包括笔从其支架中脱出的情况。更宽的目标区域则更具容错性，但受限放置试验并非总是失败。RSI 策略表现出更一致的抓取对齐，有时在一次新的尝试后能够完成回合。

精炼之前，R2 已经实现了 62.8% 的物理成功率。此处的 *zero-shot* 指的是无需针对特定任务进行真实世界策略精炼。该策略通常能够接近指定物体，而剩余的失败主要集中于抓取和放置阶段。人机协同 (HIL) 修正用于解决这些残余误差，而非从零开始提供整个策略。例如，S1 中红笔放置在仿真各个检查点处精炼前均保持为 2/10，但在 R2 精炼后提升至 7/10；眼镜放置在精炼前已达到 10/10。

这些模式表明了互补的作用：仿真中的 RSI 通过反复练习和纠正性经验发展场景特定能力，而物理精炼则解决部署后的残余误差。图 E.2 对比了一些真实世界执行的结果；附录 E 保留了所有任务级别的结果和采样间隔。测试期间的重试是学成策略的动作，而非训练阶段智能体的恢复行为。更多细节见附录 E。

5 局限性

在可用时间和计算预算范围内，我们优先评估了选定工作区内的场景特定适应性。我们计划将评估扩展至未包含的工作区以及更长的策略改进周期，以评估泛化能力与持续的策略改进效果。

我们的评估聚焦于完整的流水线，其中恢复、回忆和智能体推理协同运作。尽管本系统级研究的主要关注点并非各组件的独立贡献，但我们计划进行有针对性的消融实验，以更好地理解它们的贡献及相互作用，从而指导流水线的进一步优化。

6 结论

EmbodiRSI 通过在真实-仿真-真实（R2S2R）工作流中实现策略的递归自我改进，使经验获取能够响应不断演化的策略。借助智能体辅助，协作纠错机制可从策略失败状态提供纠正性延续，而自适应数据采集则引导练习聚焦于持续存在的弱点。基于任务特定仿真（由现实世界观测重建并经过有效轨迹生成验证），这些机制将滚动反馈转化为后续策略更新的训练经验。在仿真环境中完成递归改进后，该策略利用有限的真实世界数据进行优化，从而实现在相应物理工作空间中的自主部署。实验表明，在评估轮次中实现了自主性能的提升，在保留轨迹数量相同的情况下优于静态数据采集，并展现出高效的数据利用能力以实现真实世界的适应。综上所述，这些结果凸显了不仅应优化策略本身，还应优化驱动其改进的经验的价值。

人工智能使用声明

生成式人工智能辅助了早期稿件的结构调整、语言修订、文献核查及描述性分析代码编写。额外的人工智能辅助编辑进一步润色了本稿件，包括语言修订、现有结果的解读、LaTeX 格式排版、图表布局探索以及可编辑的向量图示。提交的实验图像均保留自提供的材料；生成的布局概念并非实验证据。

稿件准备过程中未引入新的机器人试验或仿真测量。图示仅为方法说明，非生成的实验证据。重构图库中包含用于说明的标注人工智能生成场景输入，而非评估用途。人类作者对最终文本、主张、参考文献、实施细节及人工智能使用披露负有全部责任。

可复现性声明

整个流水线的完整代码即将发布。

参考文献

Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.

Konstantinos Bousmalis, Giulia Vezzani, Dushyant Rao, Coline Devin, Alex X Lee, Maria Bauzá, Todor Davchev, Yuxiang Zhou, Agrim Gupta, Akhil Raju, et al. Robocat: A self-improving generalist agent for robotic manipulation. *arXiv preprint arXiv:2306.11706*, 2023.

Nicolas Carion, Laura Gustafson, Yuan-Ting Hu, Shoubhik Debnath, Ronghang Hu, Didac Suris Coll-Vinent, Chaitanya Ryali, Kalyan Vasudev Alwala, Haitham Khedr, Andrew Huang, et al. Sam 3: Segment anything

with concepts. In *International conference on learning representations*, volume 2026, pages 138846–138923, 2026.

Tianxing Chen, Zanxin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin, Yiheng Ge, Zhenyu Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.

Xingyu Chen, Fu-Jen Chu, Pierre Gleize, Kevin J Liang, Alexander Sax, Hao Tang, Weiyao Wang, Michelle Guo, Thibaut Hardin, Xiang Li, et al. Sam 3d: 3dfy anything in images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7220–7232, 2026.

Prithwish Dan, Kushal Kedia, Angela Chao, Edward Weiyi Duan, Maximus Adrian Pace, Wei-Chiu Ma, and Sanjiban Choudhury. X-sim: Cross-embodiment learning via real-to-sim-to-real. *arXiv preprint arXiv:2505.07096*, 2025.

Yu Fang, Yue Yang, Xinghao Zhu, Kaiyuan Zheng, Gedas Bertasius, Daniel Szafir, and Mingyu Ding. Rebot: Scaling robot learning with real-to-sim-to-real robotic video synthesis. In *2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 11351–11358. IEEE, 2025.

Haotian Fu, Ran Gong, Xiaohan Zhang, Maria Vittoria Minniti, Jigarkumar Patel, and Karl Schmeckpeper. Data-efficient multitask dagger. *arXiv preprint arXiv:2509.25466*, 2025.

Caelan Garrett, Ajay Mandlekar, Bowen Wen, and Dieter Fox. Skillmimicgen: Automated demonstration generation for efficient skill learning and deployment. *arXiv preprint arXiv:2410.18907*, 2024.

Xiaoshen Han, Junqiu Yu, Minghuan Liu, Yilun Chen, Xiaoyang Lyu, Yang Tian, Bolun Wang, Weinan Zhang, and Jiangmiao Pang. Re^{3}Sim: Generating high-fidelity simulation data via 3D-photorealistic real-to-sim for robotic manipulation. *arXiv preprint arXiv:2502.08645*, 2025.

Ryan Hoque, Ajay Mandlekar, Caelan Garrett, Ken Goldberg, and Dieter Fox. Intervengen: Interventional data generation for robust and data-efficient robot imitation learning. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 2840–2846. IEEE, 2024.

Wenlong Huang, Chen Wang, Yunzhu Li, Ruohan Zhang, and Li Fei-Fei. Rekep: Spatio-temporal reasoning of relational keypoint constraints for robotic manipulation. *arXiv preprint arXiv:2409.01652*, 2024.

Yixuan Huang, Novella Alvina, Mohanraj Devendran Shanthi, and Tucker Hermans. Fail2progress: Learning from real-world robot failures with stein variational inference. *arXiv preprint arXiv:2509.01746*, 2025.

Dongjie Huo, Haoyun Liu, Guoqing Liu, Dekang Qi, Zhiming Sun, Maoguo Gao, Jianxin He, Yandan Yang, Xinyuan Chang, Feng Xiong, et al. Abot-claw: A foundation for persistent, cooperative, and self-evolving robotic agents. *arXiv preprint arXiv:2604.10096*, 2026.

Physical Intelligence, Ali Amin, Raichelle Aniceto, Ashwin Balakrishna, Kevin Black, Ken Conley, Grace Connors, James Darpinian, Karan Dhabalia, Jared DiCarlo, et al. $\pi^*_{0.6}$: A VLA that learns from experience. *arXiv preprint arXiv:2511.14759*, 2025a.

Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025b.

Guangqi Jiang, Haoran Chang, Ri-Zhao Qiu, Yutong Liang, Mazeyu Ji, Jiyue Zhu, Zhao Dong, Xueyan Zou, and Xiaolong Wang. Gsworld: Closed-loop photo-realistic simulation suite for robotic manipulation. *arXiv preprint arXiv:2510.20813*, 2025a.

Minqi Jiang, Edward Grefenstette, and Tim Rocktäschel. Prioritized level replay. In *International Conference on Machine Learning*, pages 4940–4950. PMLR, 2021.

Zhenyu Jiang, Yuqi Xie, Kevin Lin, Zhenjia Xu, Weikang Wan, Ajay Mandlekar, Linxi Jim Fan, and Yuke Zhu. Dexmimicgen: Automated data generation for bimanual dexterous manipulation via imitation learning. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 16923–16930. IEEE, 2025b.

Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.

Ruiying Li, Yunlang Zhou, YuYao Zhu, Kylin Chen, Jingyuan Wang, Sukai Wang, Kongtao Hu, Minhui Yu, Bowen Jiang, Zhan Su, et al. Roboclaw: An agentic framework for scalable long-horizon robotic tasks. *arXiv preprint arXiv:2603.11558*, 2026.

Xinhai Li, Jialin Li, Ziheng Zhang, Rui Zhang, Fan Jia, Tiancai Wang, Haoqiang Fan, Kuo-Kun Tseng, and Ruiping Wang. Robogsim: A real2sim2real robotic gaussian splatting simulator. *arXiv preprint arXiv:2411.11839*, 2024.

Zijun Lin, Jiafei Duan, Haoquan Fang, Dieter Fox, Ranjay Krishna, Cheston Tan, and Bihan Wen. Failsafe: Reasoning and recovery from failures in vision-language-action models. *arXiv preprint arXiv:2510.01642*, 2025.

Yaru Liu, Ao-bo Wang, and Nanyang Ye. V-cage: Vision-closed-loop agentic generation engine for robotic manipulation. *arXiv preprint arXiv:2604.09036*, 2026.

Ajay Mandlekar, Soroush Nasiriany, Bowen Wen, Iretiayo Akinola, Yashraj Narang, Linxi Fan, Yuke Zhu, and Dieter Fox. Mimicgen: A data generation system for scalable robot learning using human demonstrations. *arXiv preprint arXiv:2310.17596*, 2023.

Yao Mu, Tianxing Chen, Zanxin Chen, Shijia Peng, Zhiqian Lan, Zeyu Gao, Zhixuan Liang, Qiaojun Yu, Yude Zou, Mingkun Xu, et al. Robotwin: Dual-arm robot benchmark with generative digital twins. In *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 27649–27660. IEEE, 2025.

Adithyavairavan Murali, Balakumar Sundaralingam, Yu-Wei Chao, Wentao Yuan, Jun Yamada, Mark Carlson, Fabio Ramos, Stan Birchfield, Dieter Fox, and Clemens Eppner. Graspgen: A diffusion-based framework for 6-dof grasping with on-generator training. *arXiv preprint arXiv:2507.13097*, 2025.

Shivansh Patel, Xinchen Yin, Wenlong Huang, Shubham Garg, Hooshang Nayyeri, Li Fei-Fei, Svetlana Lazebnik, and Yunzhu Li. A real-to-sim-to-real approach to robotic manipulation with vlm-generated iterative keypoint rewards. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8258–8266. IEEE, 2025.

Nicholas Pfaff, Evelyn Fu, Jeremy Binagia, Phillip Isola, and Russ Tedrake. Scalable real2sim: Physics-aware asset generation via robotic pick-and-place setups. In *2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 6296–6303. IEEE, 2025.

Stéphane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, pages 627–635. JMLR Workshop and Conference Proceedings, 2011.

Balakumar Sundaralingam, Adithyavairavan Murali, and Stan Birchfield. curobov2: Dynamics-aware motion generation with depth-fused distance fields for high-dof robots. *arXiv preprint arXiv:2603.05493*, 2026.

Tang Tao, Likui Zhang, Youpeng Wen, Kaidong Zhang, Jia-Wang Bian, Xia Zhou, Tianyi Yan, Kun Zhan, Peng Jia, Hefeng Wu, et al. Robopearls: editable video simulation for robot manipulation. In *2025 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1–12. IEEE, 2025.

Marcel Torne, Anthony Simeonov, Zechu Li, April Chan, Tao Chen, Abhishek Gupta, and Pulkit Agrawal. Reconciling reality through simulation: A real-to-sim-to-real approach for robust manipulation. *arXiv preprint arXiv:2403.03949*, 2024.

Lirui Wang, Yiyang Ling, Zhecheng Yuan, Mohit Shridhar, Chen Bao, Yuzhe Qin, Bailin Wang, Huazhe Xu, and Xiaolong Wang. Gensim: Generating robotic simulation tasks via large language models. In *International Conference on Learning Representations*, volume 2024, pages 4890–4924, 2024.

Yufei Wang, Zhou Xian, Feng Chen, Tsun-Hsuan Wang, Yian Wang, Katerina Fragkiadaki, Zackory Erickson, David Held, and Chuang Gan. Robogen: Towards unleashing infinite data for automated robot learning via generative simulation. *arXiv preprint arXiv:2311.01455*, 2023.

Zhihao Wang, Jianxiong Li, Jinliang Zheng, Wencong Zhang, Dongxiu Liu, Yinan Zheng, Haoyi Niu, Junzhi Yu, and Xianyuan Zhan. Physiagent: An embodied agent framework in physical world. *arXiv preprint arXiv:2509.24524*, 2025.

Yuxuan Wu, Lei Pan, Wenhua Wu, Guangming Wang, Yanzi Miao, Fan Xu, and Hesheng Wang. Rl-gsbridge: 3d gaussian splatting based real2sim2real method for robotic manipulation learning. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 192–198. IEEE, 2025.

Hongchi Xia, Xuan Li, Zhaoshuo Li, Qianli Ma, Jiashu Xu, Ming-Yu Liu, Yin Cui, Tsung-Yi Lin, Wei-Chiu Ma, Shenlong Wang, et al. Sage: Scalable agentic 3d scene generation for embodied ai. *arXiv preprint arXiv:2602.10116*, 2026.

Wenli Xiao, Haotian Lin, Andy Peng, Haoru Xue, Tairan He, Zhengyi Luo, Yuqi Xie, Fengyuan Hu, Jim Fan, Guanya Shi, et al. Self-improving vision-language-action models with data generation via residual rl. In *International Conference on Learning Representations*, volume 2026, pages 13209–13236, 2026.

Sheng Xu, Ruixing Jin, Huayi Zhou, Bo Yue, Guanren Qiao, Yunxin Tai, Yueci Deng, Kui Jia, and Guiliang Liu. From reaction to anticipation: Proactive failure recovery through agentic task graph for robotic manipulation. *arXiv preprint arXiv:2605.11951*, 2026.

Zhengrong Xue, Shuying Deng, Zhenyang Chen, Yixuan Wang, Zhecheng Yuan, and Huazhe Xu. Demogen: Synthetic demonstration generation for data-efficient visuomotor policy learning. *arXiv preprint arXiv:2502.16932*, 2025.

Jiazhi Yang, Kunyang Lin, Jinwei Li, Wencong Zhang, Tianwei Lin, Longyan Wu, Zhizhong Su, Hao Zhao, Ya-Qin Zhang, Li Chen, et al. Rise: Self-improving robot policy with compositional world model. *arXiv preprint arXiv:2602.11075*, 2026.

Kaifeng Zhang, Shuo Sha, Hanxiao Jiang, Matthew Loper, Hyunjong Song, Guangyan Cai, Zhuo Xu, Xiaochen Hu, Changxi Zheng, and Yunzhu Li. Real-to-sim robot policy evaluation with gaussian splatting simulation of soft-body interactions. *arXiv preprint arXiv:2511.04665*, 2025.

Mingtong Zhang and Dhruv Shah. Visual verification enables inference-time steering and autonomous policy improvement. *arXiv preprint arXiv:2606.18247*, 2026.

Haoyu Zhao, Cheng Zeng, Linghao Zhuang, Yaxi Zhao, Shengke Xue, Hao Wang, Xingyue Zhao, Zhongyu Li, Kehan Li, Siteng Huang, et al. High-fidelity simulated data generation for real-world zero-shot robotic manipulation learning with gaussian splatting. *IEEE Robotics and Automation Letters*, 2026.

Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.

Xueyang Zhou, Yihan Sun, Xijie Gong, Guiyao Tie, Pan Zhou, Lichao Sun, and Yongchao Chen. Embodiedclaw: Conversational workflow execution for embodied ai development. *arXiv preprint arXiv:2604.13800*, 2026.

Zhiyuan Zhou, Pranav Atreya, Abraham Lee, Homer Walke, Oier Mees, and Sergey Levine. Autonomous improvement of instruction following skills via foundation models. *arXiv preprint arXiv:2407.20635*, 2024.

A RSI 实现与智能体协调

附录扩展了第 3.3 节中的 RSI 环。它记录了状态条件下的交接、故障归因记录以及监督协调，区分了所提出的操作、执行的修正和最终结果。环境与轨迹构建在附录 B 中分别详细说明。

A.1 任务接口与恢复切换

任务配置将操作对象和目标锚点与语言指令、抓取候选、有序的机器人程序以及重置组相关联。每个关联的航点均遵循其源对象或目标对象的变换。重置组中的成员共享一个采样的变换，而顺序放置和碰撞处理可能会在组之间引入依赖关系。这些关联使得在重置后无需指定新的任务目标，即可重新建立同一任务相对程序的语义。

物体-路径生成器返回带有阶段标签的中间世界坐标位姿，包括抓取、可选绕行和预放置阶段。其结构化输出检查在几何审查前验证物体身份、数值有效性、位姿表示及阶段顺序。未通过的检查项可提供反馈以供候选方案修订。这将所提出的路径与其验证及后续执行相分离；仅合理的文本提案本身并非可执行的演示。

在监控仿真采集过程中，视觉诊断与恢复规划是同步进行的：控制环在等待这些操作时不会推进仿真。恢复过程使用当前物体和机器人的状态。在完成修正后返回时，会刷新观测结果并再次检查完成情况；继续执行路径可在配置的恢复门条件下将控制权交还给策略。达到可行的进入姿态并不能保证剩余操作能够顺利完成。

事件记录区分了恢复请求、实际执行的纠正动作以及最终回合的结果。一个请求可能在任何纠正措施执行前就失败，而部分执行的纠正措施之后可能接着策略完成。因此，触发恢复、执行恢复以及通过最终任务检查是三个独立的事件。这些训练数据收集到的事件也与在无辅助评估过程中观察到的由策略生成的重试行为不同。

A.2 网格归因记录与统计

网格分析使用结构化的回放记录，包括重置位置、最终结果和主体归属标签。VLM 请求可将失败归因于源对象重置、目标锚点重置或两者均不归因；该请求使用记录的执行证据，无需重新回放回放视频。现有的归属记录可重复使用，因此发出新的 VLM 请求是可选的，且不会取代规范化的网格处理流程。对于每个主体和单元，有效的已完成回合计入分母，而仅有对该主体有支持性归属的最终失败计入分子。低置信度和未分配的失败不会增加相应的归属失败计数。在恢复后成功完成的回合不计入最终失败。

A.3 主管排程与输出验证

技能与工作流状态。 主管通过一个类型化的技能库来协调工作流。

$$\mathcal{K} = \{k^{\text{scene}}, k^{\text{capture}}, k^{\text{grasp}}, k^{\text{config}}, k^{\text{motion}}, k^{\text{train}}, k^{\text{eval}}\}, \tag{A.1}$$

涵盖场景构建、观测捕获、抓取推理与验证、任务配置生成、运动合成、策略训练及受监控评估。每个技能均指定类型化的输入、明确的前提条件、执行后端以及下游操作所需的输出。持久的工作流状态是

$$s_t = (g, b, r, \mathbf{z}_t, \mathcal{J}_t, \mathcal{A}_t), \tag{A.2}$$

其中 g 为用户指定的目标，b 为请求的停止边界，r 为场景和运行标识符，$\mathbf{z}_t$ 为阶段状态，$\mathcal{J}_t$ 为异步作业，$\mathcal{A}_t$ 为索引化的制品。在执行前，监控器构建依赖链，分配特定阶段的计算资源，并固定请求的停止边界。

资格与阶段完成情况。 在时间 t 时，符合条件的技术满足

$$\mathcal{K}_t^{\text{ready}} = \{k_i \in \mathcal{K} \mid \text{Pre}_i(s_t) = 1,\ \text{Valid}(\mathcal{A}_i^{\text{req}}) = 1,\ k_i \preceq b\}. \tag{A.3}$$

此处 Pre_i 表示依赖和资源约束，$\mathcal{A}_i^{\text{req}}$ 为所需的上游构件集合，且 $k_i \preceq b$ 防止执行超出请求的边界。监控器选择 $k_t = \pi_{\text{sup}}(s_t, \mathcal{K}_t^{\text{ready}})$ 。可独立调度场景级或对象级任务，并在不同设备上并行执行。长时间运行的技能会返回一个持久的任务句柄，并通过其运行时状态、日志和构件清单进行监控。成功完成需要同时满足正常进程退出和有效所需输出：

$$\text{Complete}(k_i) = \mathbb{I}[e_i = 0] \prod_{a \in \mathcal{A}_i^{\text{out}}} \mathbb{I}[\text{Valid}(a) = 1]. \tag{A.4}$$

此处 e_i 为退出代码，$\mathcal{A}_i^{\text{out}}$ 包含下游所需的输出。持久化服务使用就绪性检查，而非进程退出语义。

故障处理。 当先决条件或构件检查失败时，监督器会定位最早的无效依赖，并请求相应的上游修复，而不是重新启动整个工作流。瞬态通信故障通过在做出新的调度决策之前恢复最新的持久化作业和阶段状态来处理。这些运行时检查支持第 3 节中描述的场景到策略的协调，而不将进程退出或接受的工具请求视为任务完成的充分证据。

B 环境与轨迹基础设施

模拟器和轨迹生成器为 RSI 提供了可复用的基础架构。附录保留了第 3.1 和 3.2 节中总结的场景编译、碰撞修正、轨迹验证以及感知重置执行的详细信息。这些工具用于初始数据收集、状态条件下的恢复以及目标数据重收集；它们并非分离的部署时控制器。

B.1 Agentic 真实世界到仿真场景的构建与优化

一个重构的工作空间只有在支持物理上有效的交互和明确的任务目标时才对学习有用。因此，我们将 Real2Sim 构建形式化为一个 *Agentic 场景编译器*：视觉与语义推理指定物体及其预期关系，而几何工具则实现并验证相应的场景操作。给定一张桌面图像，可选地附带目标图像和语言提示，该编译器生成初始场景和有组织的目标布局（图 B.1）。它们之间的差异定义了演示生成的物体级别目标。

以对象为中心的重构 视觉-语言模型（VLM）在输入图像 I_0 中识别出表格以及可见的可移动物体。SAM 3 生成实例掩码，SAM 3D 重建相应的带纹理网格 (Carion et al., 2026; Chen et al., 2026)。场景表示为

$$\mathcal{S}_0 = \{o_T, o_1, \ldots, o_N\}, \qquad o_i = (c_i, m_i, T_i^0), \tag{B.1}$$

其中 o_T 为表格，c_i 、m_i 和 $T_i^0 \in \text{SE}(3)$ 分别为物体的语义类别、网格和初始位姿。在场景编辑和轨迹生成过程中保持物体身份一致，使得指令在渲染的工作空间、几何检查和机器人程序中均指向同一物体。

仿真实例化。 场景智能体配置重构资产以进行仿真，通过设置和调整物体的尺度、位姿及物理属性，生成可执行的任务环境。在任务与轨迹生成前，对结果场景进行碰撞检测和支持关系检查。

支持感知的碰撞修正。 不完善的重构可能导致物体相互穿插，尤其是在杂乱的桌面场景中。智能体引导的自适应碰撞修正（AACR）在保留从 I_0 推断出的支持与包含关系的同时解决了这些碰撞问题。智能体首先将非桌面物体划分为具有支持感知的组 $\mathcal{G} = \{G_1, \ldots, G_K\}$。* 并行水平修正 * 通过选择一个中心根节点，将

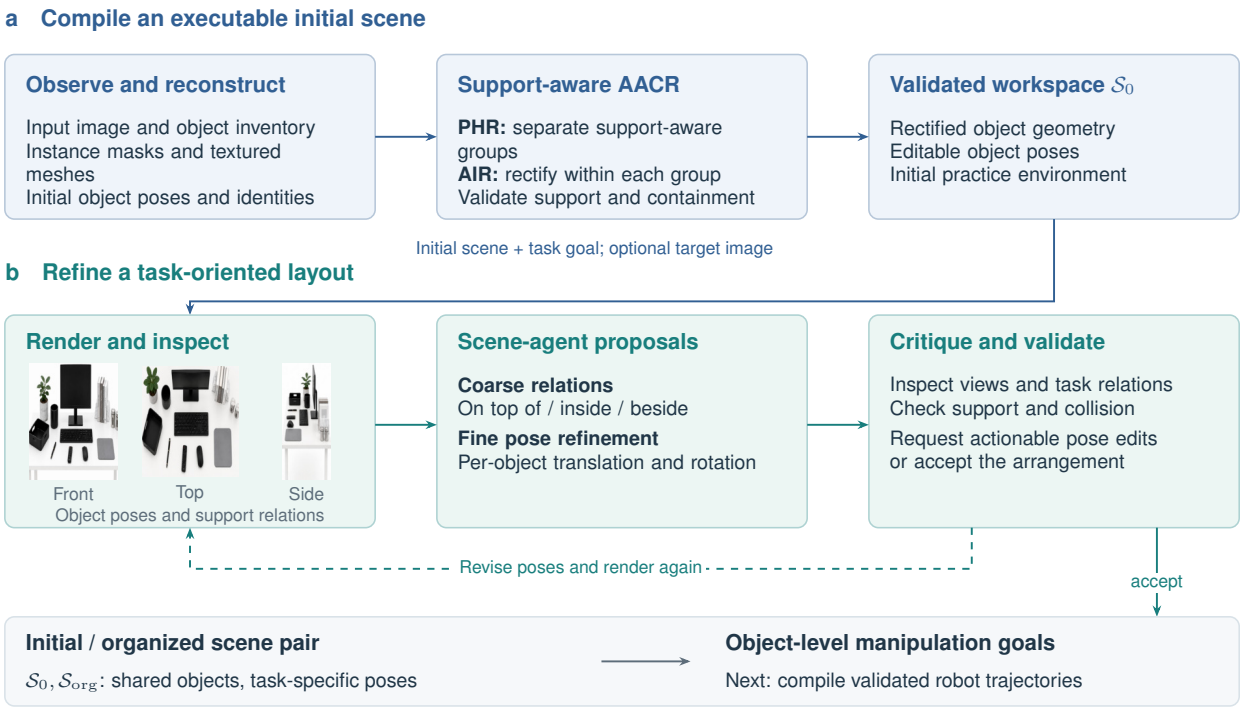


图 B.1: 从部署观察到任务定义场景。物体重构和支持感知的碰撞修正生成初始场景。场景智能体利用多视角反馈和几何验证迭代优化物体位姿，以获得目标场景。场景对定义了轨迹生成的操作目标。

其他组向外移动来分离相交的组。每组作为一个单元移动，保持其内部关系；仅当组的扫掠区域互不重叠时，才在同一并行批量中进行调整。在处理下一个批量之前，会更新已稳定集合。

自适应组内校正解决了每个组内的剩余碰撞问题。智能体根据物体关系选择相应的校正方式：对于共享支撑的物体采用水平分离，对于包含关系采用垂直调整，对于类似插入的排列采用有界倾斜。所选的几何算子执行并验证位姿变化。因此，语义推理决定了哪种调整是合适的，而不是替代碰撞检测。组选择与位移规则详见下方第 B.3 节。

面向任务的场景组织。 场景智能体将原始图像 I_0 与校正后场景的渲染结果进行比较，生成一个组织指令 $\mathcal{L}$。提供的目标图像或语言提示可进一步指定预期的布局。该智能体首先使用特定关系的工具，如 `on-top-of`、`inside` 和 `beside`，建立粗略的排列。随后，它通过并行运行的个体对象智能体对物体的平移和旋转进行精细化调整。渲染视图和结构化的对象状态使编辑的后果可供评估与修改。这一由粗到精的过程将决定“应存在何种关系”与寻找能实现该关系且不产生无效几何形状的姿态相分离。

接受的目标场景是

$$\mathcal{S}_{\text{org}} = \{(c_i, m_i, T_i^{\text{org}})\}_{i \in \{T,1,\ldots,N\}}. \tag{B.2}$$

初始和有组织的布局指定了机器人应进行更改的内容。在任务编译过程中，这些目标会与语言指令、抓取动作、航点以及重置组相关联。重置组中的物体共享一个采样的变换。随后，与源和目标相关的航点会遵循各自的锚点，使得同一任务可以在不同配置下反复练习而无需重新定义其目标。

B.2 Agentic 轨迹生成

场景对定义了期望的转移，但并未提供机器人执行该转移的可行方法。轨迹生成智能体 $\mathcal{A}_{\text{traj}}$ 通过提出物体运动、将其通过候选抓取进行投影，并验证由此产生的机器人程序来弥合这一差距。其接口是

$$\mathcal{A}_{\text{traj}} : (\mathcal{S}_0, \mathcal{S}_{\text{org}}, l) \longmapsto (\mathcal{C}, \mathcal{D}_{\text{demo}}, \mathcal{E}), \tag{B.3}$$

其中，l 为任务指令，$\mathcal{C}$ 为可执行配置的库，$\mathcal{D}_{\text{demo}}$ 包含被接受的示范，$\mathcal{E}$ 记录验证证据。相同的轨迹工具随后支持从策略失败状态中恢复以及在修改后的重置值域下的回忆。因此，示范生成是学习环中的可复用部分，而非一次性预处理阶段。

以对象为中心的任务编译。 智能体比较 $\mathcal{S}_0$ 和 $\mathcal{S}_{\text{org}}$，识别出状态必须改变的物体，并编制一个有序的子任务列表，

$$\mathcal{T} = (\chi_j)_{j=1}^{M}, \qquad \chi_j = (o_{i_j}, b_j, \rho_j). \tag{B.4}$$

此处 o_{i_j} 为被操作物体，b_j 为其目标锚点或支撑点，ρ_j 为期望的关系。顺序考虑了可达性、目标占用情况以及先前的放置位置；子任务数量 M 无需等于重建物体的数量 N。对于每个子任务，视觉语言模型（VLM）规划器提出包含提升、可选绕行和预放置姿态的物体空间路径。这些路径经过简化、优化以确保间隙，并进行加密以限定连续状态间的平移和旋转范围。在物体空间中进行规划，使得可以在选择特定抓取方式之前评估预期运动。

抓握条件驱动的运动合成。 GraspGen 提供候选抓取 (Murali et al., 2025)，这些抓取会根据抓取质量、末端可达性以及碰撞间隙进行筛选。对于物体 i 上的抓取 $T^0_{g,i}$，沿物体路径保持物体相对夹爪的变换：

$$T_{o_i \to g} = (T^0_{o_i})^{-1} T^0_{g,i}, \qquad T^j_{g,i} = T^j_{o_i} T_{o_i \to g}. \tag{B.5}$$

因此，已接受的路径可以跨抓取候选方案重复使用，而无需重新生成其语义路径。抓取和放置动作联合检查。当端点对不可达时，通过有界 SE(3) 调整联合修复抓取和放置姿态。修复后的姿态必须满足公式 Eq. (B.5) 中的共享物体相对抓取关系。预抓取、夹爪闭合、释放及释放后回退完成航点程序。

验证引导修复。 一个合理的物体路径本身并不能建立有效的演示。EmbodiRSI 在将某个配置纳入 $\mathcal{C}$ 之前会进行三项检查。首先，扫掠全网格测试会检查每个插值段上的携带物体，对有意支撑和目标接触情况有狭义的豁免。其次，多视角渲染使 VLM 审查员能够评估路径效率、姿态一致性以及对目标的接近方式。第三，cuRobo 会按顺序验证完整的机器人程序，每次转移均从先前的末端关节状态 (Sundaralingam et al., 2026) 初始化。由于携带物体的扫掠几何形状是单独检查的，因此在抓取后其过时的源位姿网格被禁用；而对场景其余部分的机器人碰撞检测则继续保持激活状态。

当转移不可行时，智能体首先尝试路径收缩，然后在第一个不可行的航点周围搜索有界局部位姿调整。修复后的候选方案必须重新通过几何和顺序运动检查，并在其目标路径发生变化时进行更新的视觉审查。只有通过释放后回缩可行的程序才会被接受。这些检查将高层级提案与可执行监督联系起来，同时允许无效候选方案被修复而非作为训练数据处理。

重置感知的执行与数据监管。 在采集时，场景物体在其允许的重置范围内随机化。物理模拟稳定后，每个存储的航点都会重新锚定到其关联源锚点或目标锚点的测量位姿 $r(j)$：

$$\widetilde{T}^j_{ee} = T^{\text{cur}}_{r(j)} (\overline{T}_{r(j)})^{-1} \overline{T}^j_{ee}, \tag{B.6}$$

上划线表示存储在配置中的位姿。每个段落均从测量到的关节状态重新规划后执行。过渡运动允许更广泛的局部位姿搜索，而抓取和放置则使用紧密限制的平面备用方案以保持任务关系。

执行过程提供第四层验证。系统在抓取后检查物体与夹爪之间的关系，验证运输过程中的指定路点，并将释放后物体的最终位姿与重置调整后的目标位姿进行比较。只有当所有验证均通过时，生成的示范才会被保留。

$$\mathrm{Accept}(\tau) = V_{\mathrm{mesh}} \wedge V_{\mathrm{view}} \wedge V_{\mathrm{motion}} \wedge V_{\mathrm{exec}}. \tag{B.7}$$

这些术语表示扫掠网格、视觉审查、顺序运动和执行时间的有效性。失败的演示将被拒绝并重新采样。已接受的记录包含多相机观测、关节状态、速度、力矩以及以 LeRobot 格式命令的动作。提议、验证、修复和执行共同将对象级任务转化为无需手动航点脚本的各种训练演示。

B.3 场景几何

平行水平校正。 AACR 将非表格对象划分为感知支持的组 $\mathcal{G} = \{G_1, \ldots, G_K\}$。PHR 在解决组间重叠时，将每组视为一个单元。令 $\mathbf{p}_k$ 表示 G_k 在桌面上的投影中心，以世界坐标表示且垂直分量为零。根组最小化到其他组的平面距离之和；每个非根组被分配相应的外向方向：

$$r = \arg\min_k \sum_{j \neq k} \|\mathbf{p}_k - \mathbf{p}_j\|_2, \qquad \mathbf{d}_k = \frac{\mathbf{p}_k - \mathbf{p}_r}{\|\mathbf{p}_k - \mathbf{p}_r\|_2}, \quad k \neq r,\ \mathbf{p}_k \neq \mathbf{p}_r. \tag{B.8}$$

位移 $\delta \mathbf{d}_k$ 是水平方向的。从已确定的锚点集 $\mathcal{H}_0 = \{G_r\}$ 出发，每个未解决的组都被赋予一个极小位移，以消除与已确定组的重叠：

$$\delta_k^* = \min\{\delta \geq 0 \mid (G_k + \delta \mathbf{d}_k) \cap \mathcal{H}_t = \emptyset\}, \qquad \widehat{G}_k = G_k + \delta_k^* \mathbf{d}_k. \tag{B.9}$$

交集指的是占据的几何区域。一种冲突感知的并行批量 $\mathcal{B}_t$ 仅包含其提议的扫掠区域互不重叠的组：

$$\mathrm{Sweep}(G_i, \widehat{G}_i) \cap \mathrm{Sweep}(G_j, \widehat{G}_j) = \emptyset, \qquad G_i, G_j \in \mathcal{B}_t,\ i \neq j. \tag{B.10}$$

此处 Sweep 表示在所提出的平移过程中遍历的区域。选定的组被同时移动，且已确定集合随之更新为

$$\mathcal{H}_{t+1} = \mathcal{H}_t \cup \{\widehat{G}_k \mid G_k \in \mathcal{B}_t\}. \tag{B.11}$$

这些方程指定了非退化的几何结构。随后，AIR 使用第 B.1 节中描述的特定于关系的水平、垂直和有限倾斜校正来处理组内重叠。

B.4 顺序动作执行

机器人的转移是按顺序规划的，前一次转移的末端关节状态被用于初始化下一次转移：

$$\xi_{i,k}^* = \mathrm{Plan}(q_{i,k-1}, T_{g,i}^k, \mathcal{W}_{i,k}), \qquad q_{i,k} = \mathrm{Last}(\xi_{i,k}^*). \tag{B.12}$$

此处 $\mathcal{W}_{i,k}$ 为用于转移的碰撞世界。在采集时间，公式 (B.6) 使用源物体或目标锚点的当前位姿重新定位每个航点。这可以保留重置后的任务相对运动。修复后会重复进行相应的几何和运动检查；当物体路径发生变化时，会重复进行视觉审查。

C 任务环境与场景重构结果

C.1 机器人平台与评估任务

第 4 节和图 3 展示了机器人平台以及配对的物理/仿真工作空间。表 C.1 列出了每个仿真–真实配对共享的全部 14 个对象级任务目标。一个策略覆盖每个场景和训练情景中的子任务；任务分别进行评估。匹配集合比较使用 S1 和 S3。

表 C.1: 操作子任务定义。对应的仿真和现实世界任务定义中，初始关系和目标关系保持固定。

Subtask	Goal
S1-1	Place glasses on the stand.
S1-2	Put the red-cap marker in the green cup.
S1-3	Put the yellow-cap marker in the basket.
S1-4	Place the mouse on the mouse pad.
S1-5	Put the red pen in the green box.
S1-6	Put the black pen in the pen holder.
S2-1	Place the blue bowl on the plate.
S2-2	Put the carrot in the basket.
S2-3	Put the eggplant in the basket.
S2-4	Put the red chilli in the basket.
S3-1	Place the soda bottle on the shelf.
S3-2	Put the pencil case in the metal box.
S3-3	Place the snack bag on the shelf.
S3-4	Put the candy wrapper in the can.

C.2 重构与组织示例

图 C.1 将选定的观测值与其重构结果并置，展示了初始布局如何定义组织目标。这些示例补充了图 3 中的实际评估环境。

图 C.2 通过一个初始布局和目标布局的示例，扩展了场景智能体工作流。它将语义评估与确定性验证分离，并补充了图 B.1 中的方法流水线。

图 C.3 展示了更多的输入-重构配对。

D 训练数据和评估协议

D.1 训练数据和保留轨迹预算

每个状态的数据预算都是指为每个子任务保留的训练轨迹数量。来自同一场景所有子任务的数据用于训练一个特定于该场景的策略。表 D.1 分离了训练经验的来源；表 D.2 和 D.3 分别给出了每个子任务和场景总计的数量。

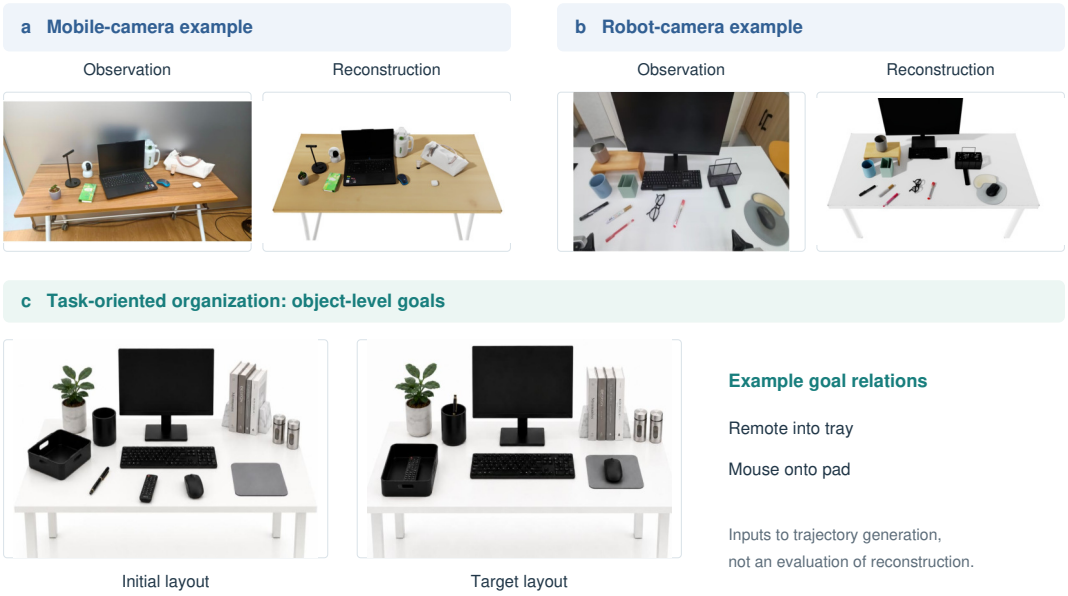


图 C.1：场景重构与组织的定性示例。 **a,b**，移动相机和机器人相机观测结果及其对应的重构场景；视角未进行像素对齐。**c**，初始布局与目标布局，展示物体级别的操作目标。

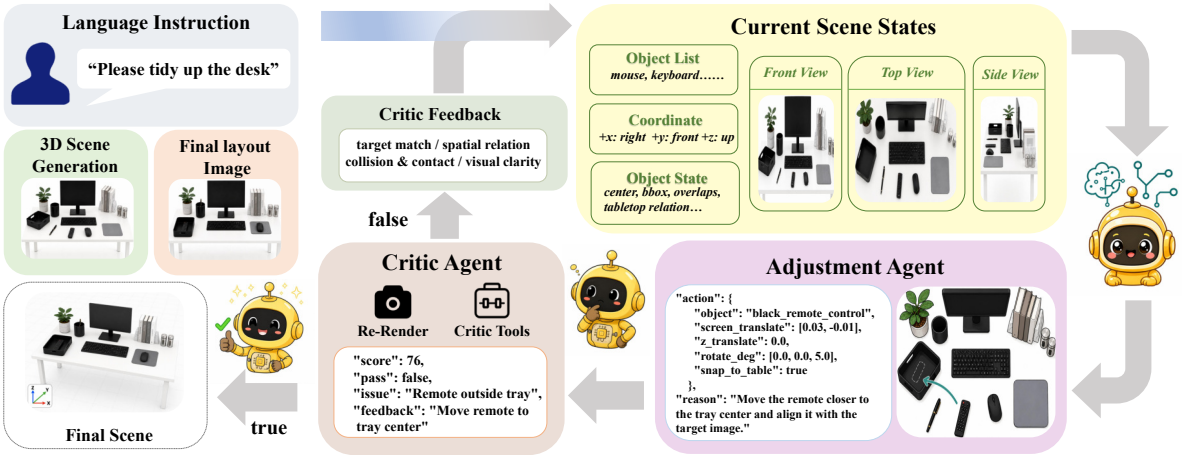


图 C.2：通过评论、编辑和验证实现的迭代场景组织。评论员将渲染视图和物体状态与目标关系进行比较，以指导姿态调整。在重新渲染之前，通过碰撞检测和支持检查来验证每次编辑。被接受的布局定义了轨迹生成中的物体级别目标。

R0 每个子任务使用 50 条生成的示范。R1 增加了 100 条新生成的和 50 条回溯衍生的轨迹；R2 再增加每类各 100 条，累计预算分别为 200 和 400。这些数量描述的是保留的训练集，而非总的获取尝试次数、转移次数或计算量。

训练数据选择。 我们的学习公式支持对成功和失败轨迹进行联合训练。然而，在报告的实验中，仅保留最终完成任务的轨迹用于策略训练。这些轨迹可能包含在纠正干预后才成功的回合，因此可能包含中间策略错误。未成功的监控回放用于故障归因和目标收集，但未纳入策略训练数据集。所有报告的训练预算均统计了保留的成功轨迹。

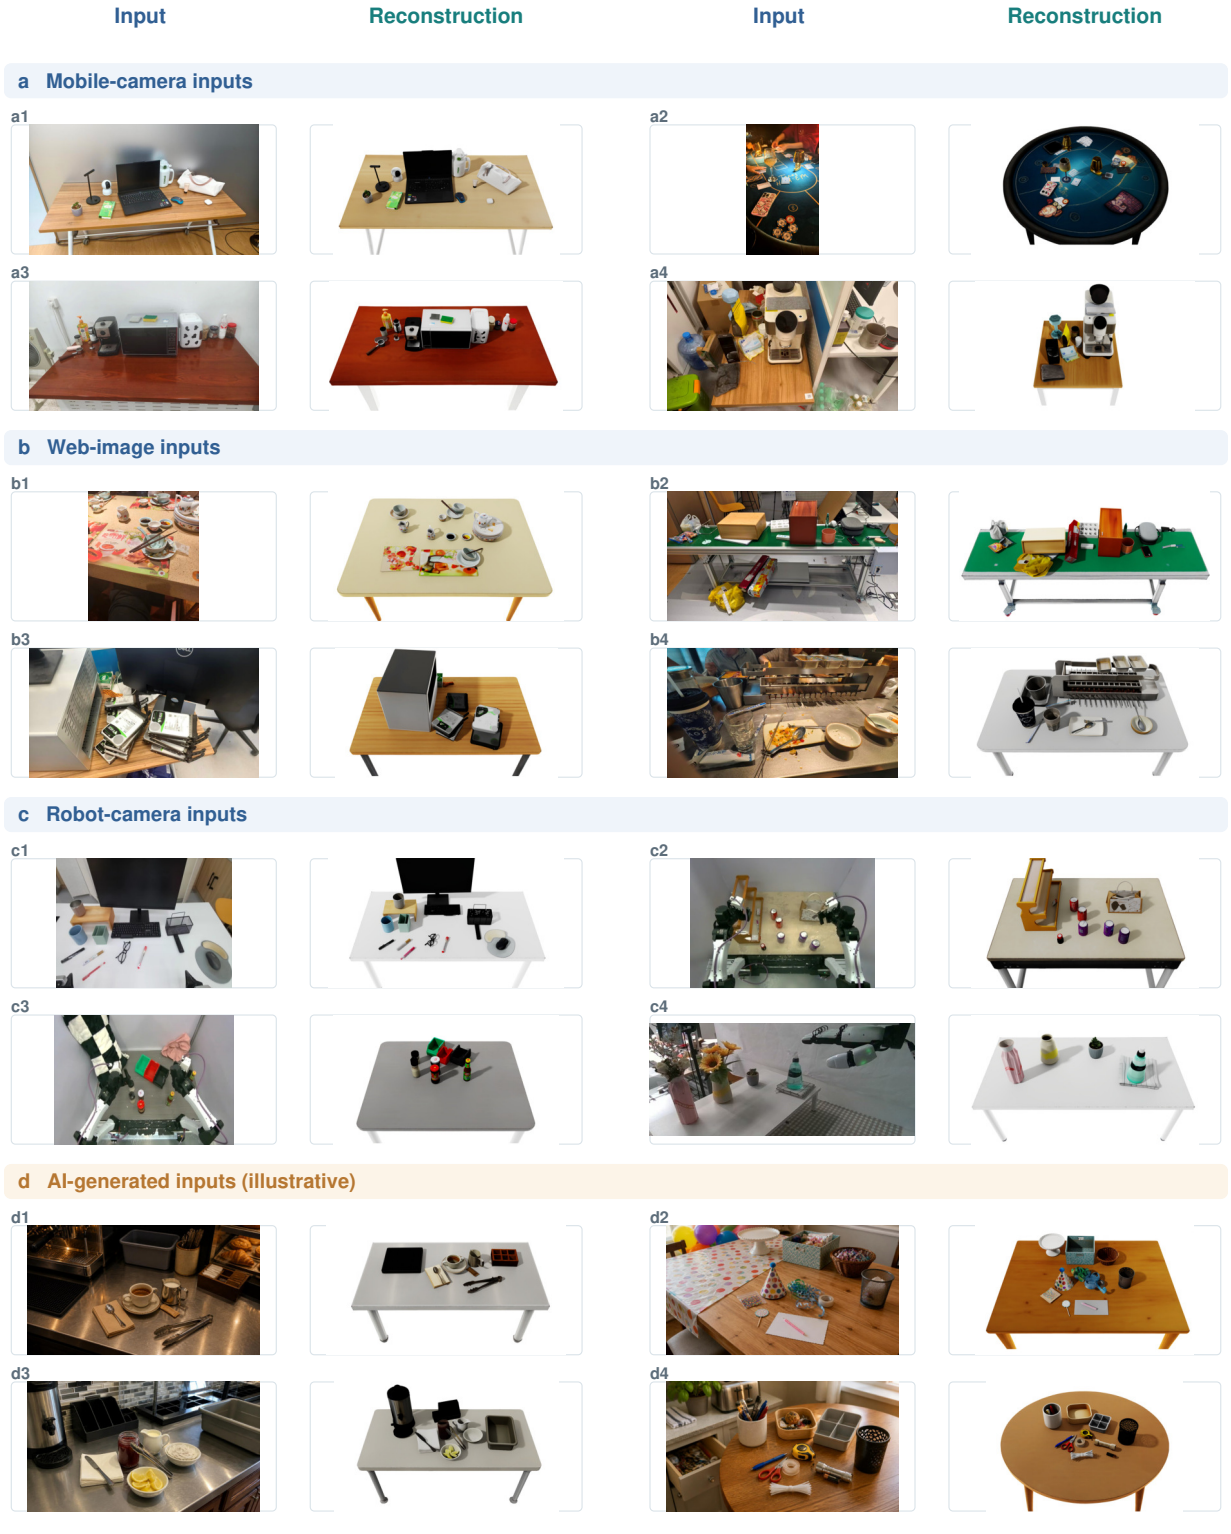


图 C.3: 定性输入–重构配对。 **a–d**，分别对应移动摄像头、网络、机器人摄像头和 AI 生成的输入。每组配对左侧为输入，右侧为重构结果。示例超出了评估基准范围；视角在姿态或尺度上未对齐。

表 D.1: 经验来源与保留数据的符号表示。该符号将监控的训练回合、纠正数据以及新生成的示范进行分离。报告的配额区分了新生成的数据与从回合中衍生的数据，但未对每种回合衍生来源进行单独计数。这些配额并未推断出基础收集与目标收集之间的数值分配。策略与纠正符号表示回合内的数据来源，而非单独计数的回合数据集。

Data item	Source and learning role	Budget accounting
$\mathcal{D}_0$	Initial validated simulation demonstrations.	50 per subtask at R0.
$\mathcal{D}_k^{\text{mon}}$	Policy-generated trajectories recorded during monitored training collection.	Part of rollout-derived data.
$\mathcal{D}_k^{\text{rec}}$	Corrections generated from eligible intermediate states reached during collection.	Part of rollout-derived data.
$\mathcal{D}_k^{\text{roll}}$	Retained data assembled from monitored and corrective sources.	50 added at R1; 100 at R2.
$\mathcal{D}_k^{\text{new}}$	Newly generated demonstrations after collection configurations are updated.	100 added at each round.
Real HIL data	Real-world training rollouts with operator corrections.	10 per subtask; pooled within scene.
Real test records	Autonomous policy evaluation, independent of HIL training.	Ten trials per subtask and setting; not training data.

表 D.2: 各子任务的仿真训练调度。两列数据为在相应阶段的新增项；总数为累计值。对于 R1/R2，新生成的示范为 $\mathcal{D}_k^{\text{new}}$ ，保留的回放衍生数据为 $\mathcal{D}_k^{\text{roll}}$ 。R0 包含初始生成的示范。统计不包括性能测试回合。

Stage	Newly generated demonstrations	Retained rollout-derived data	Cumulative total
R0	50	0	50
R1	100	50	200
R2	100	100	400

表 D.3: 场景级轨迹预算。数量等于报告的每子任务预算乘以场景策略覆盖的子任务数量。仅真实世界 10 和人机协作 +10 包含相同数量的轨迹，但属于不同的训练情景。最后一行是评估，而非训练；每个真实世界子任务在十次自主滚动中进行测试。

Dataset / evaluation	S1 (6 tasks)	S2 (4 tasks)	S3 (4 tasks)
R0 simulation training	300	200	200
R1 simulation training	1,200	800	800
R2 simulation training	2,400	1,600	1,600
HIL+10 real training	60	40	40
Real-only 10 training	60	40	40
Real-only 100 training	600	400	400
Real-only 200 training	1,200	800	800
Real test episodes per setting	60	40	40

D.2 真实世界优化与对比情景

对于每个场景，仿真演化出的策略通过每子任务保留的 10 条真实世界 HIL 训练轨迹进行优化。操作员会纠正不良执行行为，例如打滑或放置不准，并且保留的数据会标注为与仿真中使用的相同条件训练目标。各子任务的数据被汇总起来以更新共享的场景策略。最终的真实世界测试轨迹独立于 HIL 训练单独收集。

仅使用真实世界示范的基准方法在每个子任务上分别采用 10、100 和 200 条轨迹的预算，不包含特定任务的仿真阶段。这些示范由经过训练的数据采集操作员按照标准操作流程收集。静态仿真数据收集从初始示范数据集开始，在原始重置分布下持续进行；而 EmbodiRSI 则将滚动推演获得的经验与目标导向的重新采集相结合。静态与自适应对比共享每子任务 50 条轨迹的初始数据集，并匹配累计保留的轨迹数量。对比的策略采用相同的架构和训练方案。表 D.4 总结了这些情景设置。相等的真实世界轨迹预算并不意味着数据集相同；仅使用真实世界的示范与人类在环（HIL）修正属于不同的数据收集设置。

表 D.4: 训练与采集情景。每个子任务保留预算轨迹数。该表格区分了适应数据源和配置采样过程。真实数据数量相等并不意味着轨迹完全相同。

Setting	**Real-only**	**Static simulation**	**EmbodiRSI (adaptive)**
Scene policy	One per scene	One per scene	One per scene
Architecture	Same policy architecture across compared groups		
Initial simulation data	Not used	Shared 50 demonstrations per subtask	Same initial dataset as Static
Subsequent reset sampling	Real collection	Original configuration distribution	Feedback-guided configuration update
Simulation trajectory budget	None	200 or 400	200 (R1) or 400 (R2)
Training recipe	Same policy-training recipe across compared groups		
Real training source	Demonstrations at 10/100/200 per subtask	Zero-shot or +10 HIL	Zero-shot or +10 HIL
Role in comparison	Physical-data reference	Static-collection control	Adaptive-collection workflow

D.3 自主评估协议

每个子任务均使用场景训练的策略进行独立评估。智能体接管、规划器生成的恢复和人工修正功能被禁用；策略生成的重试仍属于自主执行的一部分。结果根据相应的任务定义进行评分。此处的 zero-shot 真实部署指无需针对特定任务进行真实世界策略优化；仿真本身由目标工作区观测数据构建而成。

在仿真中，每个任务-检查点组合均在其评估重置配置下进行多次回合测试。不同组合的回合数有所不同。成功率为 $r_{s,j} = 100N_{s,j}^{\text{succ}}/N_{s,j}^{\text{test}}$ ，其中 $N_{s,j}^{\text{test}}$ 为尝试的评估回合总数。这些性能测试与受监控的训练数据收集过程（记为 $\mathcal{D}^{\text{mon}}$ ）是分开的。

真实世界评估在每个子任务和情景下使用十次自主滚动，与人类示范学习训练数据收集分离，使得完全评估的情景共有 140 个测试回合。经验任务完成率为 $r_{s,j} = 100N_{s,j}^{\text{succ}}/10$。共享同一策略的子任务并非独立训练的策略副本。

D.4 统计分析与数值精度

场景级别的标准差描述了在共享同一策略的子任务之间的变化，而非独立训练运行之间的变化。任务匹配的比较并不意味着重置的回合之间存在一一对应关系。对于场景 s 具有 M_s 个子任务及任务成功率百分比 $r_{s,j}$ ，我们报告

$$\overline{r}_s = \frac{1}{M_s}\sum_{j=1}^{M_s} r_{s,j}, \qquad s_s = \sqrt{\frac{1}{M_s-1}\sum_{j=1}^{M_s}(r_{s,j}-\overline{r}_s)^2}. \tag{D.1}$$

此处 $M_1 = 6$ 与 $M_2 = M_3 = 4$ 。真实世界的数据使用整数成功次数；仿真汇总则使用表格中任务级别的百分比。对于固定的真实世界任务和训练好的策略，图 E.1 还报告了在独立二项分布模型下的逐点 95% Wilson 区间。对于 $\widehat{p} = N^{\text{succ}}/n$ 、$n = 10$ 与 $z_{.975} = 1.959964$ ，该区间为

$$\frac{\widehat{p} + z_{.975}^2/(2n) \;\pm\; z_{.975}\sqrt{\widehat{p}(1-\widehat{p})/n + z_{.975}^2/(4n^2)}}{1 + z_{.975}^2/n}. \tag{D.2}$$

主要聚合指标是场景平衡均值 $\overline{r} = \frac{1}{3}\sum_{s=1}^{3}\overline{r}_s$，报告时不包含总体标准差（SD），以区别于场景内统计量。合并的真实世界成功次数采用不同的权重：例如，R2+10 的成功次数为 116/140，而其场景平衡均值为 83.1%。收集方法差异在汇总前按子任务分别计算，$d_{s,j} = r_{s,j}^{\text{adaptive}} - r_{s,j}^{\text{static}}$。其均值和样本标准差以百分点形式报告。等场景收集比较均值仅使用 S1 和 S3。

所有计算均保留输入数据的精度，仅在最终显示的百分比、标准差和收益值中采用四舍五入至一位小数（上取整）。仿真结果对比分析使用匹配预算下的完整 S1/S3 结果；不会将静态结果外推至 S2。任务层级的方向计数中，增加、持平和减少指的是观察到的成功率，而非假设检验结果。

E 详细结果与行为观察

任务级别的结果和定性观察结果如下所述；实验和统计定义见附录 D。

E.1 仿真演化

表 E.1 报告了在数据收集与训练轮次中各任务的仿真成功情况。

E.2 现实世界迁移

表 E.2 给出了确切的物理测试次数，包括任务级别的平局和较低的观测结果。测试与人机协同训练无关，并且不包含外部修正。场景平衡和合并汇总使用不同的权重，如附录 D 中所定义。

图 E.1 展示了 R2+10 与仅真实数据 200 在任务级别上的比较，包括平局和负差异。

E.3 匹配轨迹采集对比

表 E.4 和 E.5 报告了在每子任务 200 和 400 条模拟轨迹下的完整 S1/S3 仿真与物理采集对比。在仿真中，场景均衡的自适应优势在 200 条轨迹时为 14.4 个百分点，在 400 条轨迹时为 20.6 个百分点。这些差异由表 E.4 中的任务级别百分比计算得出，S1 与 S3 的权重相等，且仅在聚合后进行四舍五入。

自适应收集在所有六个 S1 子任务以及四个 S3 子任务中的三个上表现更高，且在两种预算下均如此。在静态策略下，S3 铅笔盒任务仍略胜一筹：200 条轨迹时为 94.8% 对比 94.0%，400 条轨迹时为 97.2% 对比 96.0%。更大的静态数据集提高了所有场景的平均值，但并未改善所有任务；例如，S1 鼠标放置任务从 67.6% 下降至 59.1%。因此，总体趋势与任务层面的例外情况并存。

表 E.1: 任务级仿真成功率（%）。场景摘要报告各子任务（S1：六个；S2/S3：各四个）的均值 ± 样本标准差，而非置信区间。最后一行对各场景赋予相等权重，并不报告标准差。列标题中的数字表示每个子任务的模拟训练轨迹数。

Task	R0 (50)	R1 (200)	R2 (400)
S1: Office Table			
Glasses → stand	44.5	64.9	80.7
Red-cap marker → green cup	34.0	50.1	75.3
Yellow-cap marker → basket	26.1	30.9	57.0
Mouse → mouse pad	33.3	70.1	85.1
Red pen → green box	17.5	36.0	72.0
Black pen → pen holder	14.0	42.2	76.5
Mean ± SD	28.2 ± 11.4	49.0 ± 15.8	74.4 ± 9.7
S2: Kitchen Table			
Blue bowl → plate	75.0	84.0	86.0
Carrot → basket	90.0	94.0	98.6
Eggplant → basket	32.3	74.0	82.5
Red chili → basket	84.0	86.0	96.2
Mean ± SD	70.3 ± 26.1	84.5 ± 8.2	90.8 ± 7.8
S3: Household Table			
Soda bottle → shelf	62.0	76.0	88.0
Pencil case → metal box	72.0	94.0	96.0
Snack bag → shelf	28.6	68.0	75.5
Candy wrapper → can	48.0	76.0	82.0
Mean ± SD	52.7 ± 18.8	78.5 ± 11.0	85.4 ± 8.7
Scene-balanced mean	50.4	70.7	83.5

E.4 定性执行观察

以下观察结果补充了第 4 节中的行为观察以及图 E.2 中选定的动作序列。“重试” 表示在一次失败的交互后，由学成策略产生的动作序列，而非智能体或规划器生成的训练修正。

仿真错误与指令遵循。 遗漏抓取发生在物体的边缘位置，尽管这些位置并未显示为不可达或超出训练分布范围。在成功抓取后也发生了放置失败，特别是在物体未能进入狭窄目标开口时。这些执行错误与任务选择错误不同。在 50 次示范初始化时，策略偶尔会混淆 S1 中的红色帽标记和红色笔指令。这种混淆在更大的仿真预算下并未成为反复出现的故障模式，此时大多数错误出现在执行所请求的操作过程中。

对 R1 和 R2 的再次尝试结果不一：部分成功完成了任务，而另一些则失败了。EmbodiRSI 的学习工作流结合了不完美中间状态的经验以及在困难配置下的额外示范。

物理转移与局部矫正经验。 在硬件在环（HIL）数据采集过程中，操作员主要对最终进近、抓取和放置阶段进行了修正。经过优化后，大范围的接近动作与仿真演示结果相似，而靠近抓取和放置阶段的调整则更接

表 E.2: 任务级别的实际性能。任务条目为十次自主测试中的成功次数。场景摘要报告各子任务的平均成功率 (%) ± 样本标准差; 最后一行对各场景进行等权重处理, 不包含标准差。R1/R2 每个子任务使用 200/400 条模拟训练轨迹; +10 表示每个子任务额外增加十条真实 HIL 轨迹。Real 10/100/200 表示仅使用真实样本进行训练, 每个子任务有 10/100/200 条示范。

Task	R1	R1+10	R2	R2+10	Real 10	Real 100	Real 200
S1: Office Table							
Glasses → stand	7/10	8/10	10/10	10/10	3/10	7/10	7/10
Red-cap marker → green cup	3/10	6/10	3/10	7/10	0/10	4/10	7/10
Yellow-cap marker → basket	6/10	6/10	6/10	9/10	1/10	5/10	7/10
Mouse → mouse pad	6/10	8/10	8/10	9/10	3/10	8/10	8/10
Red pen → green box	2/10	5/10	2/10	7/10	1/10	5/10	7/10
Black pen → pen holder	2/10	5/10	3/10	7/10	0/10	5/10	6/10
Mean ± SD	43.3 ± 22.5	63.3 ± 13.7	53.3 ± 32.0	81.7 ± 13.3	13.3 ± 13.7	56.7 ± 15.1	70.0 ± 6.3
S2: Kitchen Table							
Blue bowl → plate	5/10	9/10	6/10	10/10	5/10	6/10	9/10
Carrot → basket	6/10	8/10	7/10	7/10	5/10	7/10	7/10
Eggplant → basket	6/10	8/10	9/10	8/10	4/10	6/10	8/10
Red chili → basket	7/10	8/10	6/10	9/10	4/10	6/10	7/10
Mean ± SD	60.0 ± 8.2	82.5 ± 5.0	70.0 ± 14.1	85.0 ± 12.9	45.0 ± 5.8	62.5 ± 5.0	77.5 ± 9.6
S3: Household Table							
Soda bottle → shelf	6/10	9/10	7/10	8/10	3/10	5/10	7/10
Pencil case → metal box	6/10	8/10	8/10	9/10	2/10	5/10	7/10
Snack bag → shelf	5/10	8/10	6/10	9/10	2/10	6/10	9/10
Candy wrapper → can	4/10	5/10	5/10	7/10	1/10	5/10	8/10
Mean ± SD	52.5 ± 9.6	75.0 ± 17.3	65.0 ± 12.9	82.5 ± 9.6	20.0 ± 8.2	52.5 ± 5.0	77.5 ± 9.6
Scene-balanced mean	51.9	73.6	62.8	83.1	26.1	57.2	75.0

近物理修正。这种相似性并不意味着采用在线逆运动学控制，也不代表 HIL 仅改变了与接触相关的行为。预训练策略的先验能力也起到了作用；并非所有任务知识都必须源自仿真数据。

Static+10 也受益于局部校正，但在姿态变化下一致性较差，且与改进后的演化策略相比，重新尝试的次数较少。

仅真实覆盖和任务选择。 每个子任务包含十个真实世界演示时，成功的行为主要局限于特定配置；非零的测试次数保留在表 E.2 中。包含 200 个演示的集合覆盖了比 100 个演示集合更多的配置，尽管两种策略在困难姿态下仍然容易出错，并且有时会选择与指令不一致的任务。

训练的操作员遵循标准操作流程，但在动作风格和偏好的复位配置上存在差异。覆盖不均并不会使个别示范无效，可能会导致某些困难配置的表示稀疏，同时布局、执行风格与任务标签之间的相关性可能促使依赖偶然线索而非指令。

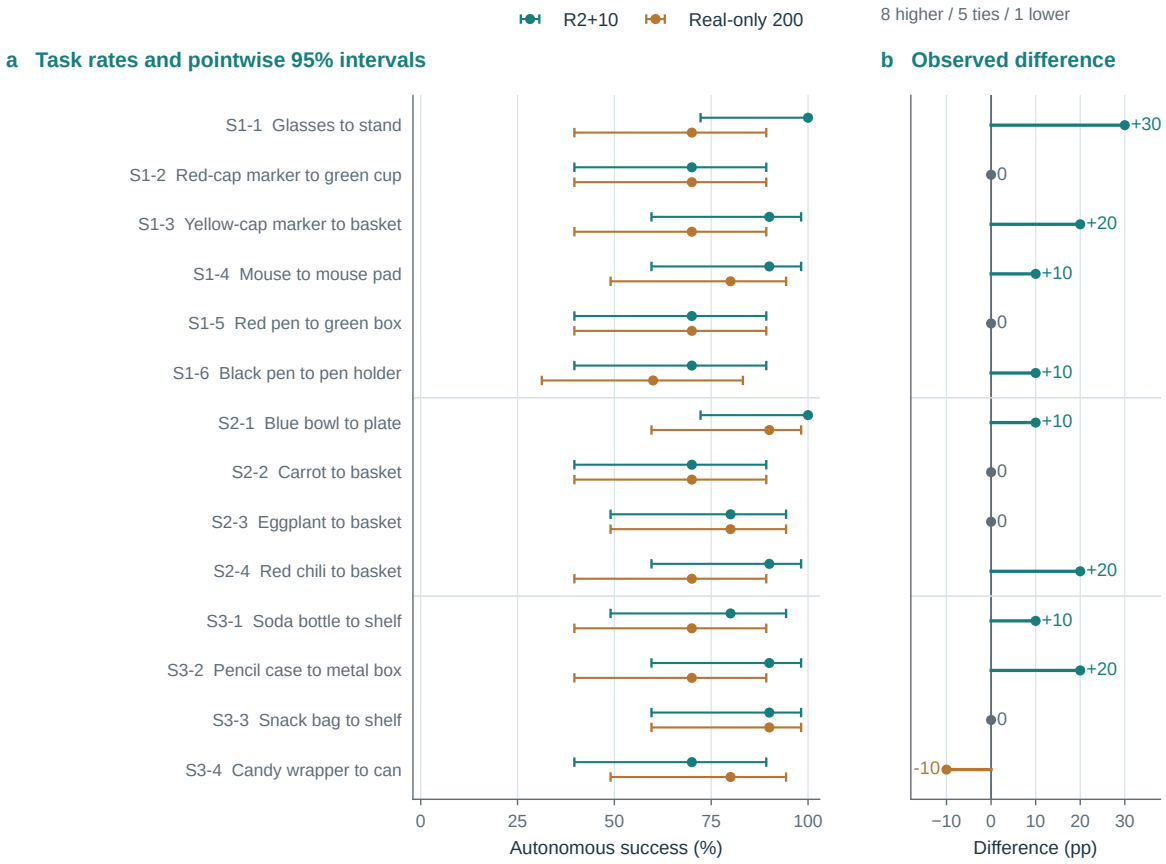


图 E.1：任务级真实世界迁移与采样准确率。 **a**, R2+10 和 Real-only 200 在每个任务和情景下的成功率为十次自主测试的点估计值，95% Wilson 置信区间。**b**, 观测到的差异按子任务身份匹配；正值表示 R2+10 更优。R2+10 每个子任务使用 400 条模拟和十条真实世界训练轨迹，而 Real-only 200 使用 200 条真实世界示范。任务 ID 参见表 C.1。

F 相关工作

F.1 自主改进与纠错经验

自主机器人学习已探索了由策略生成的经验如何支持后续的策略更新。RoboCat 使用机器人生成的数据来训练一系列通用操作模型 (Bousmalis et al., 2023)，而 SOAR 则利用基础模型引导自主经验收集与评估，以提升指令跟随能力 (Zhou et al., 2024)。PLD 训练残差强化学习专家，通过混合滚动过程收集恢复轨迹，并通过监督微调将所得数据提炼为视觉-语言-动作（VLA）模型 (Xiao et al., 2026)。这些方法为从依赖策略的经验中学习提供了先例，而非仅依赖初始示范数据集。在此研究脉络下，EmbodiRSI 关注于将策略失败状态下的纠正延续与后续采集配置的更新相耦合。其递归机制基于固定策略学习形式所获取的经验，而非通过改变学习算法本身实现。

F.2 基于失败的获取与自适应课程

策略反馈不仅能指导纠正性监督，还能引导后续训练经验的分配。数据高效多任务 DAgger 根据策略性能和估计的数据效用，将额外的专家示范分布在各个任务中 (Fu et al., 2025)。优先级层级重播通过估计其学习

表 E.3: 场景级匹配计数比较。 **a**，未进行物理精炼的仿真评估。**b**，HIL 精炼前后的真实世界性能表现。条目为各子任务间平均自主成功率（%）± 样本标准差（$n = 6$ 对应 S1，$n = 4$ 对应 S3）。Δ 为任务匹配差异的平均值 ± 标准差，单位为百分点。相等计数并不等同于总获取成本。

Scene	Sim. per subtask	HIL per subtask	Static collection	Adaptive collection	Δ (pp)
a Simulation evaluation					
S1	200	—	40.7 ± 14.6	49.0 ± 15.8	$+8.3 \pm 12.3$
	400	—	51.6 ± 10.2	74.4 ± 9.7	$+22.9 \pm 9.3$
S3	200	—	58.1 ± 28.1	78.5 ± 11.0	$+20.5 \pm 18.0$
	400	—	67.0 ± 23.2	85.4 ± 8.7	$+18.4 \pm 16.0$
b Real-world evaluation					
S1	200	0	33.3 ± 21.6	43.3 ± 22.5	$+10.0 \pm 8.9$
	200	10	48.3 ± 13.3	63.3 ± 13.7	$+15.0 \pm 5.5$
	400	0	45.0 ± 28.8	53.3 ± 32.0	$+8.3 \pm 11.7$
	400	10	68.3 ± 16.0	81.7 ± 13.3	$+13.3 \pm 10.3$
S3	200	0	40.0 ± 20.0	52.5 ± 9.6	$+12.5 \pm 12.6$
	200	10	55.0 ± 17.3	75.0 ± 17.3	$+20.0 \pm 0.0$
	400	0	47.5 ± 12.6	65.0 ± 12.9	$+17.5 \pm 5.0$
	400	10	67.5 ± 9.6	82.5 ± 9.6	$+15.0 \pm 5.8$

潜力来选择训练层级 (Jiang et al., 2021)。更直接与故障驱动生成相关的是 Fail2Progress，它合成针对观测到的故障的仿真数据，并利用这些数据来优化技能效果模型 (Huang et al., 2025)。RoboPearls 采用基于视觉语言模型的故障分析，制定针对性的仿真请求以支持进一步的策略训练 (Tao et al., 2025)。EmbodiRSI 研究了一种配置级别的获取机制：属性化回放失败引导每个任务内源对象和目标锚点重置区域的选择。评估过程保持每个子任务固定的保留数据预算，并将目标配置与基础数据集分布混合。其故障集中统计量作为获取启发式方法，而非特定配置学习增益的估计。

F.3 Agentic 工作流与执行时恢复

Agentic 系统在机器人工作流的不同层级上运行。EmbodiedClaw 将具身-人工智能开发活动，包括环境构建、轨迹合成与评估，作为可对话执行的技能暴露出来 (Zhou et al., 2026)。ABot-Claw 结合了持久的跨具身记忆与协调执行及基于反馈的修正 (Huo et al., 2026)，而 PhysiAgent 将监控与自我反思整合进物理任务执行中 (Wang et al., 2025)。在运动生成层面，ReKep 优化了视觉引导的关系关键点约束以生成机器人动作 (Huang et al., 2024)。AgentChord 在任务图中增加了预编译的恢复分支，以应对预期的执行偏差 (Xu et al., 2026)。这些机制与工作流协调和纠正性执行相关，但其作用应与 EmbodiRSI 中恢复的训练数据角色区分开来。我们的诊断与规划工具在数据收集过程中生成经验；随后，在不依赖这些外部恢复机制的情况下对更新后的策略进行评估。因此，测试时由策略生成的重试行为反映了学成的控制器，而非在线规划器的接管。

表 E.4: 任务级仿真样本收集对比。R0 是每个子任务共享的 50 条轨迹初始化。静态策略与自适应策略在每个子任务上具有相同的累计训练预算。场景行报告了各子任务间均值 ± 样本标准差。最后一行对 S1 和 S3 的权重相等；这与仿真演化表中的三场景平均值不同。

	Initial	**200 per subtask**		**400 per subtask**	
Task	R0 (50)	Static	R1	Static	R2
S1: Office Table					
Glasses → stand	44.5	32.6	64.9	41.4	80.7
Red-cap marker → green cup	34.0	47.2	50.1	59.7	75.3
Yellow-cap marker → basket	26.1	30.0	30.9	38.6	57.0
Mouse → mouse pad	33.3	67.6	70.1	59.1	85.1
Red pen → green box	17.5	35.3	36.0	48.2	72.0
Black pen → pen holder	14.0	31.5	42.2	62.5	76.5
Mean ± SD	28.2 ± 11.4	40.7 ± 14.6	49.0 ± 15.8	51.6 ± 10.2	74.4 ± 9.7
S3: Household Table					
Soda bottle → shelf	62.0	64.0	76.0	72.0	88.0
Pencil case → metal box	72.0	94.8	94.0	97.2	96.0
Snack bag → shelf	28.6	30.9	68.0	54.2	75.5
Candy wrapper → can	48.0	42.5	76.0	44.4	82.0
Mean ± SD	52.7 ± 18.8	58.1 ± 28.1	78.5 ± 11.0	67.0 ± 23.2	85.4 ± 8.7
Scene-balanced mean	40.4	49.4	63.8	59.3	79.9

表 E.5: 任务级别的真实世界数据收集对比。任务条目为十次自主测试滚动中的成功次数。所有预算均为每个子任务的训练轨迹数，且每个场景由一个策略覆盖。R1 和 R2 分别对应仿真预算为 200 和 400；+10 表示每种收集方法在每个子任务上额外增加十个真实世界 HIL 训练样本。汇总行报告了每个场景内各子任务间的平均成功率（%）± 样本标准差。

Task	Static 200	Static 200+10	R1	R1+10	Static 400	Static 400+10	R2	R2+10
S1: Office Table								
Glasses → stand	7/10	7/10	7/10	8/10	7/10	8/10	10/10	10/10
Red-cap marker → green cup	2/10	4/10	3/10	6/10	3/10	6/10	3/10	7/10
Yellow-cap marker → basket	4/10	4/10	6/10	6/10	6/10	8/10	6/10	9/10
Mouse → mouse pad	4/10	6/10	6/10	8/10	8/10	8/10	8/10	9/10
Red pen → green box	1/10	4/10	2/10	5/10	1/10	4/10	2/10	7/10
Black pen → pen holder	2/10	4/10	2/10	5/10	2/10	7/10	3/10	7/10
Mean ± SD	33.3 ± 21.6	48.3 ± 13.3	43.3 ± 22.5	63.3 ± 13.7	45.0 ± 28.8	68.3 ± 16.0	53.3 ± 32.0	81.7 ± 13.3
S3: Household Table								
Soda bottle → shelf	5/10	7/10	6/10	9/10	5/10	6/10	7/10	8/10
Pencil case → metal box	5/10	6/10	6/10	8/10	6/10	8/10	8/10	9/10
Snack bag → shelf	5/10	6/10	5/10	8/10	5/10	7/10	6/10	9/10
Candy wrapper → can	1/10	3/10	4/10	5/10	3/10	6/10	5/10	7/10
Mean ± SD	40.0 ± 20.0	55.0 ± 17.3	52.5 ± 9.6	75.0 ± 17.3	47.5 ± 12.6	67.5 ± 9.6	65.0 ± 12.9	82.5 ± 9.6

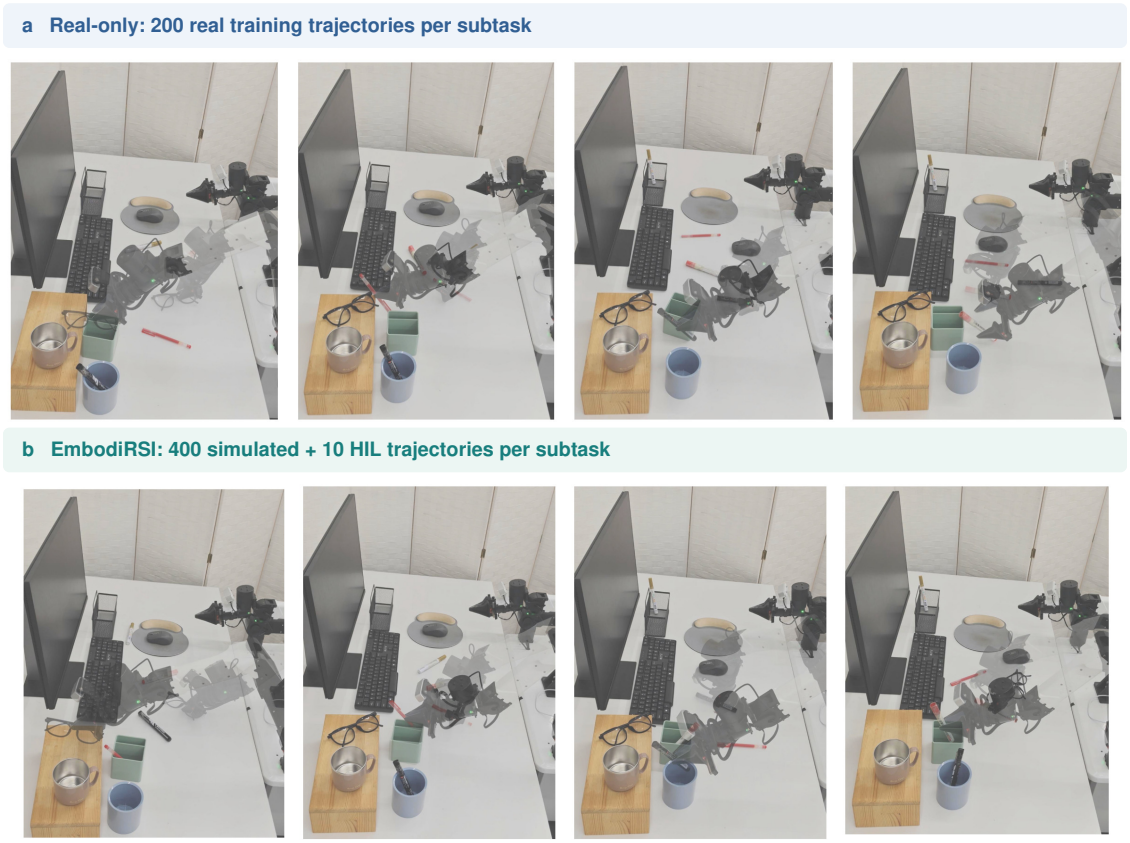


图 E.2：示例性的自主真实世界执行。 **a**, 仅使用真实数据的适应，每个子任务包含 200 个真实演示。**b**, EmbodiRSI 使用每子任务 400 个模拟和 10 个真实 HIL 轨迹。所有测试仅使用学成策略。定量结果见表 2。